Trường Đại học Khoa học tự nhiên

Khoa Toán - Tin học

Học phần: Xử lý số liệu thống kê

Năm học: 2025 - 2026

BÁO CÁO ĐỒ ÁN CUỐI KÌ

PROJECT 5:

CDC DIABETES HEALTH INDICATORS

Giảng viên môn học: TS. Tô Đức Khánh

Nhóm K

Lê Vũ Uyễn Nhi – 22110145

Lý Mẫn Nhi – 22110146

Nguyễn Bửu Đăng Quang – 22110175

Trần Thị Tú Quỳnh – 22110186

Mục lục

1 Giới thiệu **5**
1.1 Về bộ dữ liệu 5
1.2 Về đồ án này 6

2 Thống kê mô tả và khám phá dữ liệu: **8**
2.1 Xem xét biến mục tiêu Diabetes_012 8
2.2 Gộp biến và xem xét biến mục tiêu Diabetes_binary 9
2.3 Xem xét biến đóng góp BMI 9
2.4 Xem xét các biến đóng góp nhị phân 12
2.5 Xem xét các biến đóng góp định tính theo thứ bậc 14
2.6 Xem xét sự tương quan của tất cả các biến với biến mục tiêu . 15

3 Phương pháp Bootstrap và Empirical Likelihood (CI) cho BMI **17**
3.1 Tóm tắt nguyên lý về phương pháp Bootstrap và phương pháp Empirical Likelihood 17
3.1.1 Phương pháp Bootstrap 17
3.1.2 Phương pháp Empirical Likelihood (EL) 18
3.1.3 Lý do vì sao lựa chọn hai phương pháp cho bài toán này 18
3.2 Trường hợp 1: Phân tích theo biến gốc `Diabetes_012` 18
3.2.1 Bootstrap khoảng tin cậy 95% cho BMI trung bình . . 19
3.2.2 Empirical Likelihood cho khoảng tin cậy 95% của BMI trung bình 20
3.2.3 So sánh khoảng tin cậy 95% giữa hai phương pháp . . 21
3.2.4 So sánh BMI giữa nhóm không tiểu đường và có tiểu đường (`Diabetes_012 = 0` và `Diabetes_012 = 2`) . . 21
3.3 Trường hợp 2: Gộp biến Diabetes_012 = 1 và Diabetes_012 = 2 thành biến nhị phân Diabetes_binary = 1 – người có tiểu đường 22
3.3.1 Bootstrap khoảng tin cậy 95% cho BMI trung bình . . 23
3.3.2 Empirical Likelihood cho khoảng tin cậy 95% của BMI trung bình 24
3.3.3 So sánh khoảng tin cậy 95% giữa hai phương pháp . . 25
3.3.4 So sánh BMI giữa nhóm không tiểu đường và có tiểu đường (`Diabetes_binary = 0` và `Diabetes_binary = 1`) 25

3.4 So sánh sự khác biệt giữa 2 cách mã hóa biến tiểu đường . . . 27
3.5 Tổng hợp kết quả theo câu hỏi nghiên cứu 28
3.5.1 Câu hỏi 1: Khoảng tin cậy 95% cho BMI trung bình của nhóm có tiểu đường 28
3.5.2 Câu hỏi 2: So sánh BMI giữa người có và không mắc tiểu đường 29

4 Kiểm định giả thuyết thống kê 29
4.1 Kiểm định Chi-bình phương 30
4.2 Kiểm định hoán vị 31
4.3 Tổng kết 32

5 Tiêu chí chọn biến cho mô hình 33
5.1 Chọn biến từ tương quan Pearson giữa các biến với biến mục tiêu `Diabetes_binary` 33
5.2 Chọn biến phân loại nhị phân từ Chi-bình phương 34
5.3 Chọn biến từ Information Value (IV) và Weight of Evidence (WOE) 34
5.3.1 Weight of Evidence (WOE) 34
5.3.2 Information Value (IV) 35
5.4 Tổng kết 36

6 Xây dựng mô hình hồi quy Logistic và mô hình Multinomal Logistic 37
6.1 Mục tiêu 37
6.2 Mô hình hồi quy logistic 38
6.2.1 Ước lượng mô hình trên tập dữ liệu gốc 39
6.2.2 Tiên đoán mô hình trên tập dữ liệu gốc 44
6.2.3 Ước lượng mô hình trên tập dữ liệu cân bằng 45
6.2.4 Tiên đoán mô hình trên tập dữ liệu cân bằng 49
6.2.5 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu gốc 49
6.2.6 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu gốc 53
6.2.7 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu cân bằng 54
6.2.8 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu cân bằng 57

6.3 Mô hình hồi quy multinomial logistic 58
6.3.1 Ước lượng mô hình trên tập dữ liệu gốc 58
6.3.2 Tiên đoán mô hình trên tập dữ liệu gốc 62
6.3.3 Ước lượng mô hình trên tập dữ liệu cân bằng 63
6.3.4 Tiên đoán mô hình trên tập dữ liệu cân bằng 63
6.3.5 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu gốc 64
6.3.6 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu gốc 66
6.3.7 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu cân bằng 66
6.3.8 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu cân bằng 67

7 Xây dựng mô hình GAM Logistic 68
7.1 Khái niệm chung 68
7.2 So sánh với hồi quy Logistic cổ điển 69
7.3 Mô hình GAM giữa 21 biến đóng góp so với biến Diabetes_binary. 69
7.4 Mô hình GAM giữa 21 biến đóng góp so với biến Diabetes_012. 73
7.5 Mô hình GAM giữa 11 biến so với biến Diabetes_binary . . . 76

8 Đề xuất loại bỏ biến theo phương pháp đệ quy 77
8.1 Mục đích 77
8.2 Phương pháp thực hiện 77
8.3 Kết quả lựa chọn biến 78

Bảng phân công.

MSSV	**Họ và tên**	**Các phần đã làm**
22110145	Lê Vũ Uyễn Nhi	Phần 1 2, 7, tổng hợp Rmd
22110146	Lý Mẫn Nhi	Phần 3, 8, tổng hợp Latex
22110175	Nguyễn Bửu Đăng Quang	Phần 4, 5, 6
22110186	Trần Thị Tú Quỳnh	Phần 6

1 Giới thiệu

1.1 Về bộ dữ liệu

Bệnh tiểu đường là một căn bệnh mãn tính phổ biến nhất trên thế giới. Đây là căn bệnh mãn tính khiến mọi người mất khả năng điều chỉnh hiệu quả lượng glucose trong máu và có thể dẫn đến giảm chất lượng cuộc sống và tuổi thọ. Các biến chứng như bệnh tim, mất thị lực, cắt cụt chi dưới và bệnh thận có liên quan đến lượng đường cao mãn tính vẫn còn trong máu đối với những người mắc bệnh tiểu đường. Mặc dù không có cách chữa khỏi bệnh tiểu đường, nhưng các chiến lược như giảm cân, ăn uống lành mạnh, vận động và điều trị y tế có thể làm giảm tác hại của căn bệnh này ở nhiều bệnh nhân. Chẩn đoán sớm có thể dẫn đến thay đổi lối sống và điều trị hiệu quả hơn, khiến các mô hình dự đoán nguy cơ mắc bệnh tiểu đường trở thành công cụ quan trọng đối với cộng đồng và các quan chức y tế công cộng.

Trong đồ án này, bộ dữ liệu được sử dụng chứa thông tin khảo sát của 253,680 người dân Hoa Kỳ vào năm 2015, với 22 biến được quan sát, bao gồm 3 biến định lượng là *BMI*,*GenHlth*, *PhysHlth*, 4 biến định tính thứ bậc *Age*, *Education*, *Income*, *GenHlth* và các biến còn lại là định tính. Trong đó, các biến có dạng như sau:

- *Diabetes_012*: tình trạng bệnh tiểu đường (0: không tiểu đường, 1: tiền tiểu đường, 2: tiểu đường);
- *HighBP*: tình trạng cao huyết áp (0/1);
- *HighChol*: tình trạng cao cholesterol (0/1);
- *CholCheck*: kiểm tra cholesterol trong 5 năm (0/1);
- *BMI*: Chỉ số khối cơ thể (Body Mass Index);
- *Smoke*: người đã hút ít nhất 100 điếu thuốc trong suốt cuộc đời (0/1), [lưu ý: 5 gói = 100 điếu thuốc];
- *Stroker*: đã từng đột quỵ (0/1);
- *HeartDiseaseorAttack*: bệnh tim mạch vành (CHD) hoặc nhồi máu cơ tim (MI) (0/1);

- *PhysActivity*: hoạt động thể chất trong vòng 30 ngày, không tính hoạt động liên quan tới công việc (0/1);
- *Fruits*: có ăn trái cây ít nhất 1 lần mỗi ngày (0/1);
- *Veggies*: có ăn rau/củ ít nhất 1 lần mỗi ngày (0/1);
- *HvyAlcoholConsump*: uống rượu/bia ở mức "nặng" (heavy drinking) (0/1);
- *AnyHealthcare*: có bảo hiểm y tế hoặc có khả năng tiếp cận dịch vụ chăm sóc sức khỏe (0/1);
- *NoDocbcCost*: trong 12 tháng qua có từng không đi khám bác sĩ vì chi phí quá cao (0/1);
- *GenHlth*: tự đánh giá sức khỏe tổng quát (1: Excellent → 5: Poor);
- *MentHlth*: số ngày sức khỏe tinh thần không tốt trong 30 ngày gần nhất (0–30);
- *PhysHlth*: số ngày sức khỏe thể chất không tốt trong 30 ngày gần nhất (0–30);
- *DiffWalk*: gặp khó khăn khi đi bộ hoặc leo cầu thang (0/1);
- *Sex*: giới tính (0: nữ, 1: nam);
- *Age*: tuổi (13 nhóm);
- *Education*: cấp giáo dục đã hoàn thành (6 cấp giáo dục);
- *Income*: mức thu nhập (8 mức);
- *GenHlth*: điểm tự đánh giá sức khỏe chung (5 mức).

1.2 Về đồ án này

Trong bài đồ án cuối kỳ này, nhóm thực hiện bài đồ án này qua bốn bước như sau:

- **Thống kê mô tả và khám phá dữ liệu:** Nhóm thực hiện tìm hiểu các biến có trong bộ dữ liệu, vì mục tiêu cuối cùng là xem xét về căn bệnh tiểu đường nên nhóm thực hiện kiểm tra các biến có thể là nguy cơ dẫn đến bệnh tiểu đường chẳng hạn như chỉ số BMI hay huyết áp cao thấp hay cả giới tính bằng cách trực quan và xem độ tương quan. Cuối cùng đưa ra quyết định sẽ xem xét bộ dữ liệu trên cả hai biến là *Diabetes_012* tức phân loại bệnh tiểu đường trên 3 mức: không tiểu đường, tiền tiểu đường và tiểu đường, và biến *Diabetes_binary* tức phân loại bệnh tiểu đường trên 2 mức: không tiểu đường và có nguy cơ bị tiểu đường.

- **Phân tích BMI:** Trong bước phân tích BMI, nhóm thực hiện quy trình phân tích BMI trung bình cho các nhóm phân loại bệnh tiểu đường, với mục tiêu xác định mối liên hệ giữa chỉ số BMI và các nhóm tiểu đường khác nhau. Cụ thể, nhóm thực hiện so sánh BMI giữa nhóm không tiểu đường và có tiểu đường của hai biến *Diabetes_012* và *Diabetes_binary*, và so sánh sự khác biệt giữa biến ban đầu và biến gộp. Trong có sử dụng hai phương pháp Bootstrap và Empirical Likelihood.

- **Kiểm định giả thuyết:** Sau khi phân tích BMI, nhóm thực hiện kiểm định giả thuyết thống kê để kiểm tra sự khác biệt giữa nhóm bị tiểu đường và nhóm không bị tiểu đường về các chỉ số sức khỏe quan trọng. Cụ thể, nhóm tiến hành tiếp tục kiểm định sự khác biệt BMI của người mắc tiểu đường và không để đưa ra kết luận cuối, thực hiện những kiểm định về sự liên hệ của biến đối với biến mục tiêu. Cuối cùng chọn biến sẽ sử dụng từ hệ số tương quan pearson, kiểm định chi bình phương và các phép biến đổi khác.

- **Mô hình hóa:** Dựa trên kết quả từ các bước phân tích trước đó, đặc biệt là phân tích BMI và kiểm định giả thuyết, nhóm tiến hành bước mô hình hóa nhằm đánh giá khả năng dự đoán tình trạng bệnh tiểu đường từ các yếu tố nguy cơ đã được xác định. Cụ thể, nhóm sử dụng mô hình hồi quy Logistic, mô hình hồi quy Logistic đa thức và GAM Logistic từ các biến đã suy luận, sau cùng phân loại các bệnh nhân tiểu đường.

2 Thống kê mô tả và khám phá dữ liệu:

2.1 Xem xét biến mục tiêu Diabetes_012

Nhóm tiến hành thống kê số lượng và tỷ lệ phần trăm của từng nhóm trong biến mục tiêu *Diabetes_012* thể hiện tình trạng bệnh tiểu đường của cá nhân với ba mức như bên dưới nhằm đánh giá phân bố dữ liệu ban đầu.

- 0 - không tiểu đường.
- 1 - tiền tiểu đường.
- 2 - tiểu đường.

Kết quả cho thấy dữ liệu bị mất cân bằng nghiêm trọng, trong đó nhóm không tiểu đường (0) chiếm tỷ lệ áp đảo (khoảng 82.71%), trong khi nhóm tiền tiểu đường (1) và tiểu đường (2) chỉ chiếm lần lượt khoảng 2.01% và 15.27%. Sự mất cân bằng này có thể gây ảnh hưởng đến các phân tích và mô hình hóa ở các bước tiếp theo, đặc biệt là các mô hình dự đoán.

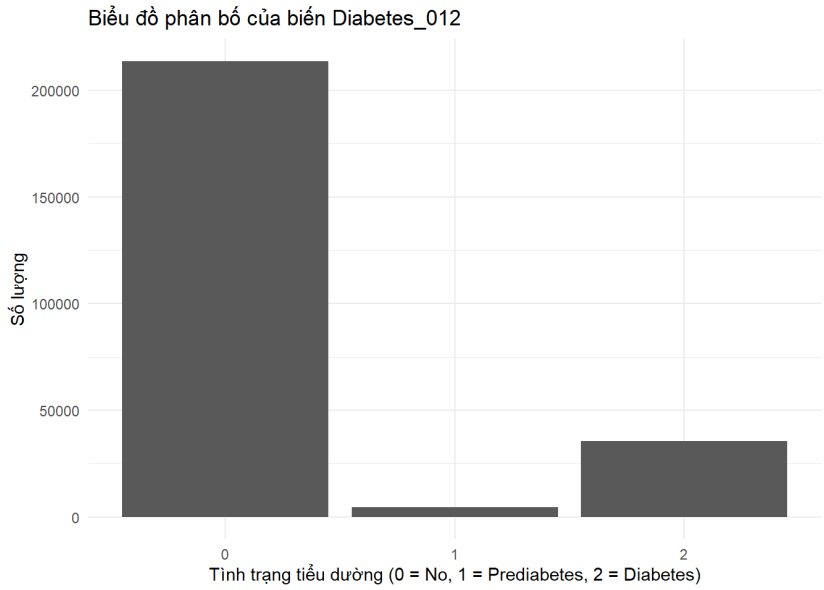

Hình 1: Số lượng các nhóm trong biến *Diabetes_012*.

Do đó, nhóm xem xét việc biến đổi biến mục tiêu nhằm đơn giản hóa bài toán và giảm ảnh hưởng của mất cân bằng lớp.

2.2 Gộp biến và xem xét biến mục tiêu Diabetes_binary

Từ biến *Diabetes_012* ban đầu, nhóm tiến hành gộp biến để tạo ra biến mục tiêu mới *Diabetes_binary*, các biến bao gồm:

- 0 - không tiểu đường.
- 1 - có nguy cơ tiểu đường (bao gồm tiền tiểu đường và tiểu đường).

Nhằm đơn giản hóa biến mục tiêu; tăng kích thước mẫu của nhóm "có nguy cơ tiểu đường"; giảm mức độ mất cân bằng lớp trong dữ liệu. Sau khi gộp, tỷ lệ của nhóm "có nguy cơ tiểu đường" tăng lên khoảng 15.76%. Tuy nhiên, dữ liệu vẫn còn tồn tại tình trạng mất cân bằng, do đó vấn đề này tiếp tục được lưu ý trong các bước phân tích tiếp theo.

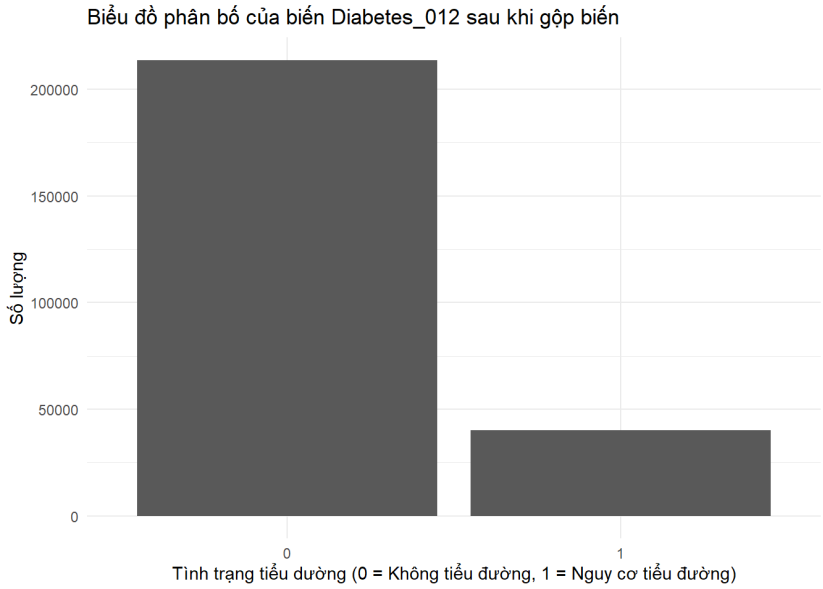

Hình 2: Số lượng các nhóm trong mới gộp biến *Diabetes_binary*.

2.3 Xem xét biến đóng góp BMI

BMI (Body Mass Index) là chỉ số khối cơ thể, được tính dựa trên cân nặng và chiều cao của mỗi cá nhân và là một trong những yếu tố nguy cơ quan trọng liên quan đến bệnh tiểu đường. Dưới đây là bảng phân loại chỉ số cơ thể (BMI) dựa trên WHO.

Bảng 1: Phân loại chỉ số khối cơ thể (BMI)

Chỉ số khối cơ thể (BMI)	**Phân loại**	**Nguy cơ phát triển bệnh**
< 18.5	Gầy	Thấp
$18.5 - 24.9$	Bình thường	Trung bình
$25.0 - 29.9$	Hơi béo	Cao
$30.0 - 34.9$	Béo phì cấp độ 1	Cao
$35.0 - 39.9$	Béo phì cấp độ 2	Rất cao
≥ 40.0	Béo phì cấp độ 3	Nguy hiểm

Nhóm tiến hành phân tích thống kê mô tả và trực quan hóa biến BMI để đánh giá đặc điểm phân phối của biến này.

Thống kê mô tả cho thấy giá trị median BMI là 27.0, cao hơn ngưỡng BMI bình thường, trong khi mean BMI là 28.38, lớn hơn median, cho thấy phân phối BMI lệch phải do sự xuất hiện của các giá trị BMI cao. Khoảng tứ phân vị (IQR) cho thấy phần lớn các quan sát nằm trong khoảng từ BMI bình thường đến béo phì độ 1. Tiếp theo, nhóm tiến hành trực quan hai biến trên biểu đồ boxplot.

Thông qua biểu đồ boxplot theo cả hai biến *Diabetes_012* và *Diabetes_binary*, nhóm nhận thấy BMI của nhóm không tiểu đường luôn thấp hơn so với các nhóm còn lại. Kết quả này nhất quán cho cả trường hợp biến mục tiêu ban đầu và biến mục tiêu sau khi gộp.

Đối với biến tiểu đường cũ *(Diabetes_012)*, giá trị BMI trung vị có xu hướng tăng dần theo mức độ bệnh, trong đó nhóm không tiểu đường (0) có BMI thấp nhất, tiếp đến là nhóm tiền tiểu đường (1) và cao nhất là nhóm tiểu đường (2). Điều này cho thấy BMI có mối liên hệ rõ ràng với mức độ nghiêm trọng của bệnh tiểu đường. Ngoài ra, cả ba nhóm đều xuất hiện nhiều giá trị ngoại lai ở phía trên, phản ánh sự tồn tại của các cá nhân có chỉ số BMI rất cao, đặc biệt phổ biến ở nhóm mắc tiểu đường.

Đối với biến tiểu đường mới *(Diabetes_binary)*, sau khi gộp nhóm tiền tiểu đường và tiểu đường, sự khác biệt về BMI giữa hai nhóm trở nên rõ ràng hơn. Nhóm có nguy cơ tiểu đường (1) có BMI trung vị cao hơn đáng kể so với nhóm không tiểu đường (0), đồng thời độ phân tán của BMI cũng lớn

hơn. Kết quả này cho thấy việc gộp biến giúp làm nổi bật sự khác biệt tổng thể về BMI giữa hai nhóm chính, đồng thời giảm nhiễu do kích thước mẫu nhỏ của nhóm tiền tiểu đường trong biến ban đầu.

Nhìn chung, cả hai biểu đồ đều cho thấy BMI là một yếu tố nguy cơ quan trọng liên quan đến bệnh tiểu đường, và kết quả trực quan này tạo cơ sở cho các bước phân tích định lượng sâu hơn như xây dựng khoảng tin cậy, kiểm định giả thuyết và mô hình hóa ở các phần tiếp theo.

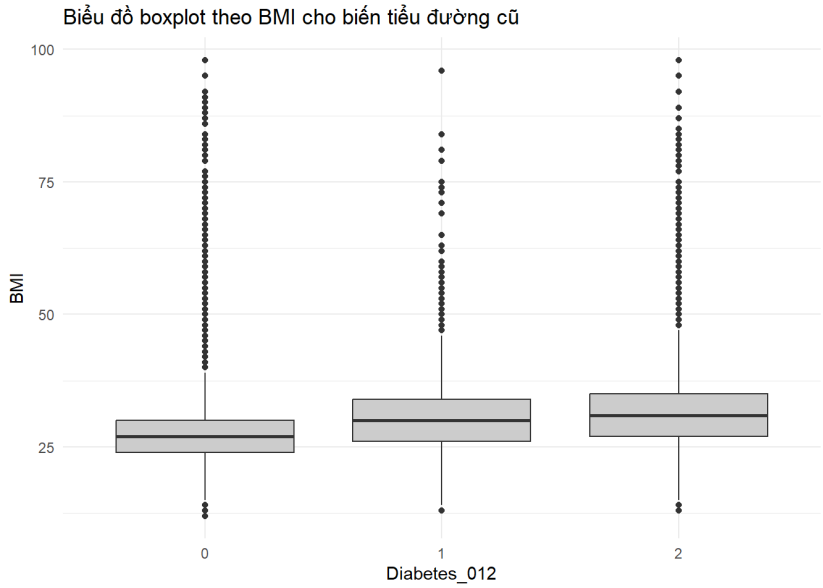

Hình 3: Biểu đồ boxplot theo BMI cho biến *Diabetes_012*.

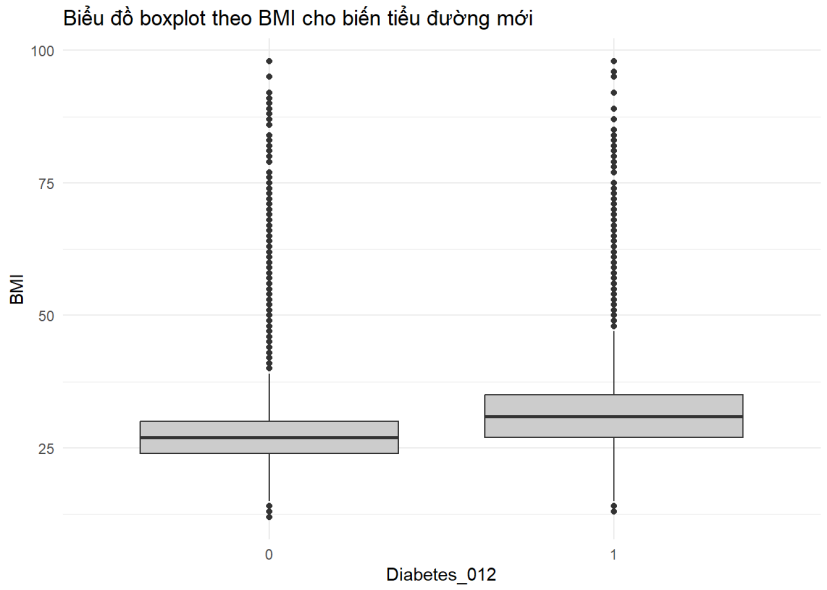

Hình 4: Biểu đồ boxplot theo BMI cho biến *Diabete_ binary*.

2.4 Xem xét các biến đóng góp nhị phân

Kết quả phân tích cho thấy hai biến *Diabetes_ binary* và phản ánh xu hướng tương đồng trong việc mô tả mối liên hệ giữa các biến giải thích và tình trạng tiểu đường. Do đó, trong các phần xem xét mức độ đóng góp của các biến tiếp theo, nhóm lựa chọn sử dụng biến *Diabetes_ binary* nhằm đơn giản hóa biến mục tiêu, đồng thời giảm ảnh hưởng của mất cân bằng lớp và tăng tính ổn định cho các phân tích sau.

Nhóm tiếp tục phân tích các biến nhị phân liên quan đến tình trạng sức khỏe và hành vi lối sống, bao gồm: cao huyết áp, cholesterol cao, hút thuốc, đột quỵ, bệnh tim mạch, hoạt động thể chất, tiêu thụ rượu bia, bảo hiểm y tế, khả năng tiếp cận dịch vụ y tế và giới tính.

Bảng 2: So sánh các biến nhị phân theo tình trạng tiểu đường với 0 là không bị tiểu đường và 1 là có nguy cơ tiểu đường.

Biến	**0 (%)**	**1 (%)**
Cao huyết áp (HighBP)	37.1	73.8
Cholesterol cao (HighChol)	37.9	66.4
Đã kiểm tra cholesterol (CholCheck)	95.7	99.2
Hút thuốc (Smoker)	43.0	51.5
Đột quỵ (Stroke)	3.16	8.84
Bệnh tim mạch / nhồi máu cơ tim (HeartDiseaseorAttack)	7.18	21.4
Hoạt động thể chất (PhysActivity)	77.9	63.6
Ăn trái cây thường xuyên (Fruits)	64.3	58.7
Ăn rau thường xuyên (Veggies)	82.1	75.8
Uống rượu bia mức nặng (HvyAlcoholConsump)	6.18	2.60
Có bảo hiểm y tế (AnyHealthcare)	95.0	95.8
Không đi khám do chi phí (NoDocbcCost)	7.96	10.9
Khó khăn khi đi lại (DiffWalk)	13.2	36.0
Giới tính nam (Sex = 1)	43.4	47.4

Kết quả so sánh theo biến *Diabetes_binary* cho thấy:

- Cả nam và nữ đều có nguy cơ mắc bệnh tiểu đường.
- Người nguy cơ mắc tiểu đường ít hoạt động thể chất hơn so với người không mắc tiểu đường.
- Tỷ lệ bệnh tim mạch cao hơn rõ rệt ở nhóm mắc tiểu đường so với nhóm nguy cơ.
- Đột quỵ phổ biến hơn ở người mắc tiểu đường.
- Hút thuốc không cho thấy mối liên hệ rõ ràng với tình trạng tiểu đường.
- Người mắc tiểu đường có xu hướng được theo dõi y tế thường xuyên hơn.
- Cholesterol cao phổ biến hơn đáng kể ở người mắc tiểu đường.
- Cao huyết áp có mối liên hệ đáng kể với tình trạng tiểu đường.

2.5 Xem xét các biến đóng góp định tính theo thứ bậc

Các biến định tính theo thứ bậc được xem xét bao gồm: Age, Education, Income và GenHlth. Nhóm tập trung phân tích phân bố của các biến này trong nhóm có nguy cơ tiểu đường.

Bảng 3: Phân bố nhóm tuổi trong nhóm có nguy cơ tiểu đường

Nhóm tuổi	**Số lượng (n)**	**Tỷ lệ (%)**
1	99	0.25
2	194	0.49
3	386	0.97
4	768	1.92
5	1214	3.04
6	2054	5.14
7	3506	8.77
8	4813	12.0
9	6435	16.1
10	7255	18.2
11	5743	14.4
12	3848	9.63
13	3662	9.16

Bảng 4: Phân bố trình độ học vấn trong nhóm có nguy cơ tiểu đường

Trình độ học vấn	**Số lượng (n)**	**Tỷ lệ (%)**
1	49	0.12
2	1344	3.36
3	2610	6.53
4	12416	31.1
5	11687	29.2
6	11871	29.7

Bảng 5: Phân bố thu nhập trong nhóm có nguy cơ tiểu đường

Mức thu nhập	**Số lượng (n)**	**Tỷ lệ (%)**
1	2697	6.75
2	3442	8.61
3	3989	9.98
4	4513	11.3
5	5091	12.7
6	6039	15.1
7	6000	15.0
8	8206	20.5

Bảng 6: Tự đánh giá sức khỏe chung trong nhóm có nguy cơ tiểu đường

Mức sức khỏe	**Số lượng (n)**	**Tỷ lệ (%)**
1 (Excellent)	1453	3.63
2 (Very good)	7595	19.0
3 (Good)	15185	38.0
4 (Fair)	10815	27.0
5 (Poor)	4929	12.3

Kết quả cho thấy:

- Người mắc tiểu đường tập trung chủ yếu ở nhóm trung niên và cao tuổi;
- Trình độ học vấn chủ yếu ở mức cao đẳng/đại học và sau đại học;
- Nhóm có nguy cơ tiểu đường tập trung nhiều ở nhóm thu nhập cao;
- Phần lớn người mắc tiểu đường tự đánh giá sức khỏe ở mức trung bình.

Do biến Education cho thấy sự phụ thuộc nhiều vào biến tuổi, nhóm quyết định loại bỏ biến này trong các bước phân tích và mô hình hóa tiếp theo.

2.6 Xem xét sự tương quan của tất cả các biến với biến mục tiêu

Cuối cùng, nhóm tiến hành phân tích hệ số tương quan Pearson giữa tất cả các biến và biến mục tiêu *Diabetes_binary* nhằm đánh giá mức độ liên hệ

tuyến tính giữa các biến.

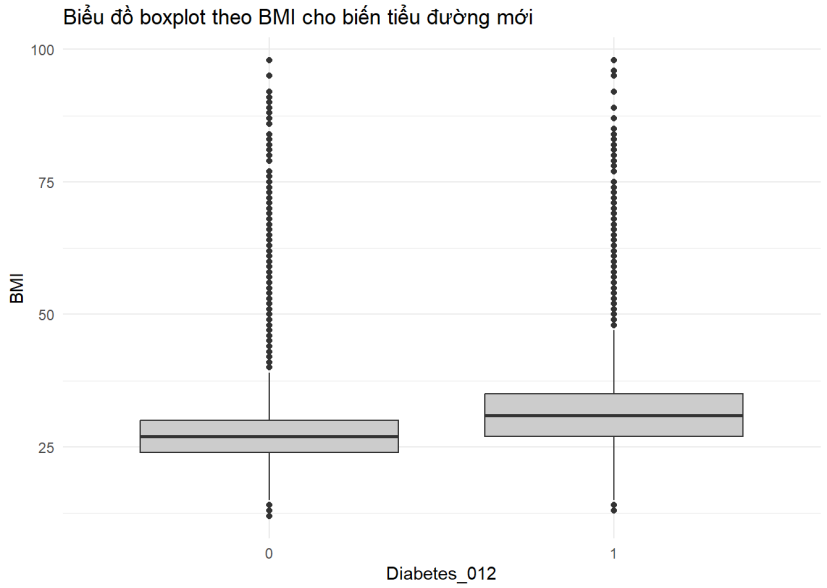

Hình 5: Xem xét sự tương quan của các biến đóng góp đối với biến *Diabetes_binary*.

Biểu đồ thể hiện hệ số tương quan Pearson giữa các biến giải thích và biến mục tiêu *Diabetes_binary*. Nhìn chung, đa số các biến có mức độ tương quan từ yếu đến trung bình, tuy nhiên vẫn thể hiện những xu hướng rõ ràng và phù hợp với thực tế y khoa.

Các biến có tương quan dương cao nhất với *Diabetes_binary* bao gồm *GenHlth, HighBP, BMI, DiffWalk, HighChol* và *Age*. Trong đó, biến *GenHlth* có hệ số tương quan lớn nhất, cho thấy tình trạng sức khỏe kém có mối liên hệ mạnh với nguy cơ mắc tiểu đường. Bên cạnh đó, cao huyết áp, chỉ số BMI cao và cholesterol cao cũng thể hiện mối liên hệ rõ ràng, phản ánh vai trò quan trọng của các yếu tố chuyển hóa và tim mạch trong bệnh tiểu đường.

Ngược lại, một số biến có tương quan âm với biến mục tiêu, đáng chú ý là *Income, Education* và *PhysActivity* cho thấy thu nhập cao hơn, trình độ học vấn cao hơn và mức độ hoạt động thể chất nhiều hơn có xu hướng liên quan đến nguy cơ tiểu đường thấp hơn.

Các biến như *Sex, AnyHealthcare, Fruits, Veggies* và *HvyAlcoholConsump* có hệ số tương quan rất nhỏ, gần bằng 0, cho thấy mức độ liên hệ yếu và khả năng phân biệt thấp đối với tình trạng tiểu đường khi xét riêng lẻ.

Tổng thể, kết quả phân tích tương quan giúp nhóm xác định được các biến tiềm năng để đưa vào các bước kiểm định giả thuyết và mô hình hóa hồi quy logistic, đồng thời cũng cho thấy rằng không có biến đơn lẻ nào có mối quan hệ tuyến tính quá mạnh, từ đó nhấn mạnh vai trò của mô hình đa biến trong việc dự đoán bệnh tiểu đường.

3 Phương pháp Bootstrap và Empirical Likelihood (CI) cho BMI

Trong phần này, nhóm tập trung trả lời hai câu hỏi nghiên cứu chính:
(i) Khoảng tin cậy 95% cho BMI trung bình của nhóm mắc tiểu đường là bao nhiêu?
(ii) BMI của người mắc tiểu đường có thực sự khác biệt so với người không mắc tiểu đường hay không?

Để đảm bảo kết luận không phụ thuộc vào cách mã hóa biến tiểu đường, nhóm tiến hành phân tích dưới hai trường hợp biến mục tiêu: biến gốc `Diabetes_012` và biến gộp `Diabetes_binary`.

Cả hai trường hợp đều được phân tích bằng hai phương pháp phi tham số là phương pháp Bootstrap và phương pháp Empirical Likelihood (EL) nhằm so sánh và kiểm tra tính nhất quán của các khoảng tin cậy và chênh lệch trung bình BMI.

3.1 Tóm tắt nguyên lý về phương pháp Bootstrap và phương pháp Empirical Likelihood

3.1.1 Phương pháp Bootstrap

Bootstrap là phương pháp phi tham số dựa trên việc lấy mẫu lại có hoàn lại từ dữ liệu gốc để xấp xỉ phân phối của thống kê quan tâm, chẳng hạn như trung bình hoặc chênh lệch trung bình.
Thông qua phân phối thực nghiệm thu được từ các mẫu Bootstrap, khoảng

tin cậy có thể được xây dựng mà không cần giả định dạng phân phối của biến nghiên cứu.

Với mẫu quan sát $x_1, \ldots, x_n$ của nhóm cần ước lượng, Bootstrap được thực hiện như sau:

1. Lặp B lần: lấy mẫu lại có hoàn lại để thu được $x_1^{*(b)}, \ldots, x_n^{*(b)}$.
2. Tính thống kê quan tâm, ví dụ $\bar{x}^{*(b)}$ hoặc $\Delta^{*(b)}$.
3. Dùng phân phối thực nghiệm của $\{\bar{x}^{*(b)}\}_{b=1}^{B}$ (hoặc $\{\Delta^{*(b)}\}$) để suy ra khoảng tin cậy 95% (percentile CI hoặc BCa nếu nhóm có dùng).

3.1.2 Phương pháp Empirical Likelihood (EL)

Empirical Likelihood là phương pháp phi tham số xây dựng khoảng tin cậy cho tham số dựa trên tối đa hóa hàm hợp lý thực nghiệm dưới các ràng buộc moment.
Phương pháp này cho phép suy luận thống kê mà không cần giả định phân phối, đồng thời vẫn giữ được cấu trúc tương tự phương pháp likelihood truyền thống.
Empirical Likelihood xây dựng CI dựa trên tối đa hóa hàm hợp lý thực nghiệm dưới ràng buộc moment.Với điều kiện $\sum_{i=1}^{n} p_i = 1$, $p_i \geq 0$ và $\sum_{i=1}^{n} p_i(x_i - \mu) = 0$, ta xét tỉ số EL để suy ra miền tin cậy cho μ (dựa trên xấp xỉ χ^2 của thống kê log-likelihood ratio).

3.1.3 Lý do vì sao lựa chọn hai phương pháp cho bài toán này

Bootstrap và Empirical Likelihood được lựa chọn vì đây là hai phương pháp phi tham số phù hợp cho việc xây dựng khoảng tin cậy cho trung bình và chênh lệch trung bình mà không phụ thuộc vào giả định phân phối của dữ liệu.
Ngoài ra, việc sử dụng đồng thời hai phương pháp có bản chất khác nhau giúp đánh giá tính ổn định của kết quả và tăng độ tin cậy cho kết luận thống kê.

3.2 Trường hợp 1: Phân tích theo biến gốc `Diabetes_012`

Trong trường hợp này, nhóm sử dụng biến mục tiêu gốc `Diabetes_012` và đối chiếu hai nhóm: `Diabetes_012 = 0` (không tiểu đường) và `Diabetes_012 = 2` (tiểu đường).

Ở phần này, nhóm tiền tiểu đường `Diabetes_012 = 1` bị loại bỏ nhằm tập trung vào sự khác biệt giữa hai trạng thái rõ ràng nhất: không tiểu đường và tiểu đường.

	n	mean_BMI
Không tiểu đường	213,703	27.74
Mắc tiểu đường	35,346	31.94

Bảng 7: Thống kê mô tả BMI theo tình trạng tiểu đường

Nhận xét: Qua bảng thống kê mô tả, ta nhìn thấy được BMI trung bình của nhóm mắc tiểu đường cao hơn đáng kể so với nhóm không mắc tiểu đường, đồng thời kích thước mẫu lớn ở cả hai nhóm tạo điều kiện thuận lợi cho việc áp dụng các phương pháp suy luận phi tham số trong các phần tiếp theo.

3.2.1 Bootstrap khoảng tin cậy 95% cho BMI trung bình

Tiến hành phương pháp Bootstrap để xây dựng khoảng tin cậy 95% cho BMI trung bình.

2.5%	**97.5%**
31.86844	32.02281

Biểu đồ phân phối Bootstrap:

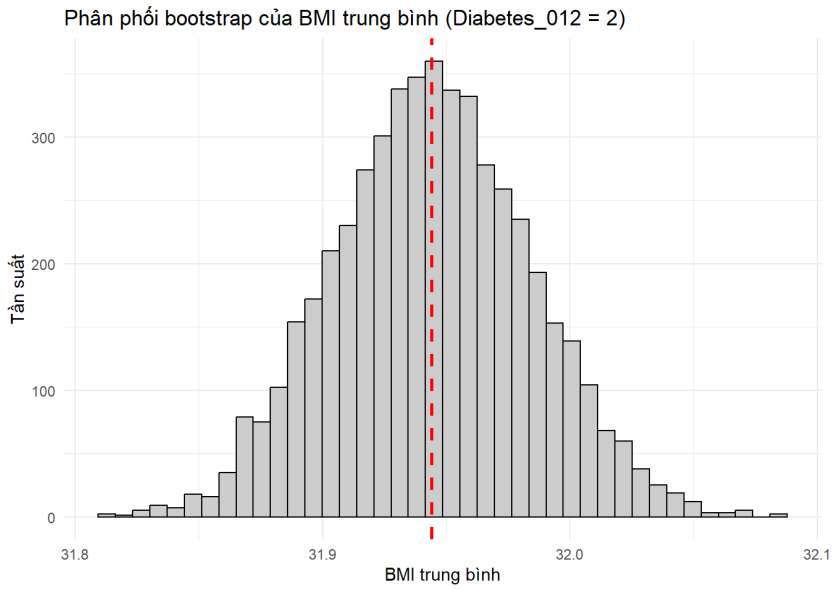

Hình 6: Biểu đồ phân phối bootstrap BMI trung bình (`Diabetes_012=2`)

Nhận xét:

- BMI trung bình của nhóm mắc tiểu đường (Diabetes_012 = 2) được ước lượng là 31.94.
- Khoảng tin cậy 95% theo phương pháp Bootstrap cho BMI trung bình là [31.87; 32.02].
- Khoảng tin cậy này cho thấy giá trị trung bình BMI của quần thể mà mẫu đại diện được ước lượng nằm trong khoảng từ 31.87 đến 32.02.

Kết luận: Theo phân loại của WHO, giá trị BMI trung bình này thuộc ngưỡng **béo phì cấp độ 1**.

3.2.2 Empirical Likelihood cho khoảng tin cậy 95% của BMI trung bình

Tiến hành phương pháp Empirical Likelihood để xây dựng khoảng tin cậy 95% cho BMI trung bình.

mean	lower	upper
31.80274	31.73125	31.87494

Nhận xét:

- BMI trung bình của nhóm mắc tiểu đường (`Diabetes_012 = 2`) được ước lượng là 31.94.
- Khoảng tin cậy 95% theo phương pháp Empirical Likelihood cho BMI trung bình là [31.87; 32.02].

Kết luận: Với độ tin cậy 95%, BMI trung bình của quần thể người bị tiểu đường nằm trong khoảng trên. Kết quả EL phù hợp với cách ước lượng phi tham số và không phụ thuộc giả định phân phối chuẩn của BMI.

3.2.3 So sánh khoảng tin cậy 95% giữa hai phương pháp

Phương pháp	Trung bình	Giới hạn dưới	Giới hạn trên	Độ rộng
Bootstrap	31.94	31.87	32.02	0.154
EL	31.94	31.87	32.02	0.154

Bảng 8: So sánh khoảng tin cậy 95% giữa phương pháp Bootstrap và Empirical Likelihood

Nhận xét: Khoảng tin cậy 95% thu được từ phương pháp Bootstrap và Empirical Likelihood trùng nhau về cả vị trí và độ rộng. Điều này cho thấy ước lượng BMI trung bình của nhóm có tiểu đường là ổn định và không nhạy cảm với phương pháp xây dựng khoảng tin cậy.
Kết luận: Với khoảng tin cậy 95% theo phương pháp Bootstrap và Empirical Likelihood đều cho ra cùng một kết quả là BMI trung bình của người mắc tiểu đường (`Diabetes_012 = 2`) nằm trong nhóm phân loại **Béo phì cấp độ 1** theo WHO.

3.2.4 So sánh BMI giữa nhóm không tiểu đường và có tiểu đường (`Diabetes_012 = 0` và `Diabetes_012 = 2`)

2.5%	97.5%
4.120858	4.282107

Biểu đồ chênh lệch Bootstrap:

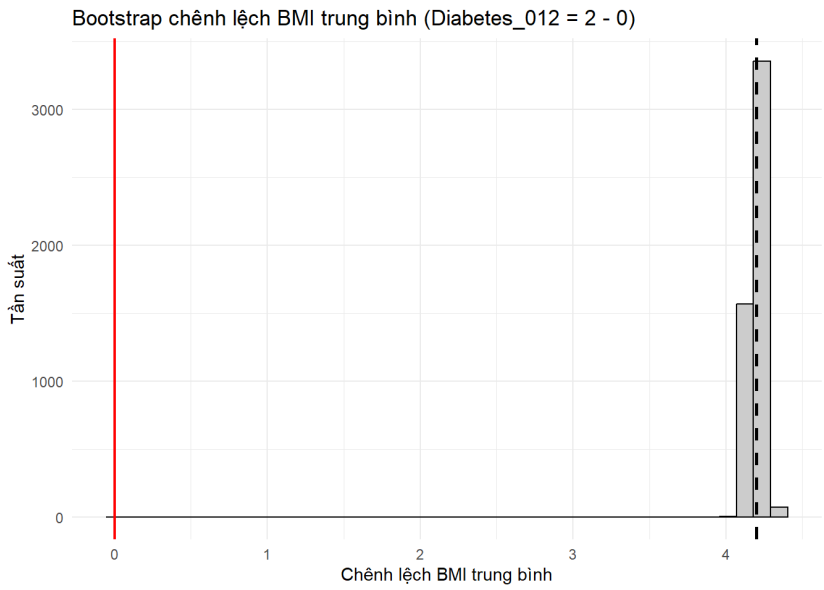

Hình 7: Biểu đồ phân phối bootstrap chênh lệch BMI trung bình (`Diabetes_012=2-0`)

Nhận xét:

- Chênh lệch BMI trung bình giữa nhóm mắc tiểu đường và nhóm không tiểu đường là 4.2.
- Khoảng tin cậy bootstrap 95% cho chênh lệch này là [4.12; 4.28].
- Khoảng tin cậy không chứa 0, cho thấy BMI của người mắc tiểu đường cao hơn đáng kể so với người không mắc tiểu đường.

3.3 Trường hợp 2: Gộp biến Diabetes_012 = 1 và Diabetes_012 = 2 thành biến nhị phân Diabetes_binary = 1 – người có tiểu đường

Trong phân tích này, nhóm có tiểu đường (bao gồm tiền tiểu đường và tiểu đường) được mã hóa bởi biến `Diabetes_binary = 1` và được so sánh với nhóm không tiểu đường.

	n	mean_BMI
Không tiểu đường	213,703	27.74
Mắc tiểu đường	39,977	31.80

Bảng 9: Thống kê mô tả BMI theo tình trạng tiểu đường

Nhận xét: Qua bảng thống kê mô tả, ta nhìn thấy được BMI trung bình của nhóm mắc tiểu đường cao hơn đáng kể so với nhóm không mắc tiểu đường, đồng thời kích thước mẫu lớn ở cả hai nhóm tạo điều kiện thuận lợi cho việc áp dụng các phương pháp suy luận phi tham số trong các phần tiếp theo.

3.3.1 Bootstrap khoảng tin cậy 95% cho BMI trung bình

Tiến hành phương pháp Bootstrap tương tự như trường hợp 1 để xây dựng khoảng tin cậy 95% cho BMI trung bình.

2.5%	**97.5%**
31.73177	31.87318

Biểu đồ phân phối Bootstrap:

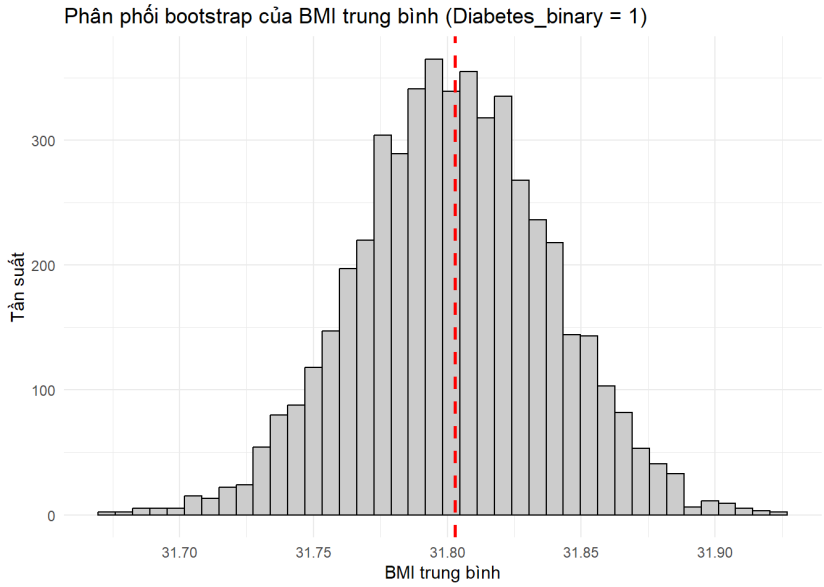

Hình 8: Biểu đồ phân phối bootstrap BMI trung bình (`Diabetes_binary=1`)

Nhận xét:

- Phân phối có dạng gần đối xứng và xấp xỉ chuẩn, tập trung mạnh quanh giá trị trung bình quan sát (đường đứt nét), cho thấy ước lượng BMI trung bình là ổn định.
- Độ phân tán của phân phối bootstrap tương đối nhỏ, phản ánh độ bất định thấp của ước lượng trung bình BMI nhờ kích thước mẫu lớn.
- Khoảng tin cậy 95% được xây dựng dựa trên phân phối này phản ánh mức độ bất định của ước lượng.
- Khoảng tin cậy 95% theo phương pháp Bootstrap cho BMI trung bình là [31.73; 31.87].

Kết luận: Theo phân loại của WHO, giá trị BMI trung bình này thuộc ngưỡng **béo phì cấp độ 1**.

3.3.2 Empirical Likelihood cho khoảng tin cậy 95% của BMI trung bình

Tiến hành phương pháp Empirical Likelihood tương tự trường hợp 1 để xây dựng khoảng tin cậy 95% cho BMI trung bình.

mean	lower	upper
31.80274	31.73125	31.87494

Nhận xét:

- BMI trung bình của nhóm mắc tiểu đường (`Diabetes_binary = 1`) được ước lượng là 31.80.
- Khoảng tin cậy 95% theo phương pháp Empirical Likelihood cho BMI trung bình là [31.73; 31.87].

Kết luận: Với độ tin cậy 95%, BMI trung bình của quần thể người bị tiểu đường nằm trong khoảng trên. Kết quả EL phù hợp với cách ước lượng phi tham số và không phụ thuộc giả định phân phối chuẩn của BMI.

3.3.3 So sánh khoảng tin cậy 95% giữa hai phương pháp

Phương pháp	Trung bình	Giới hạn dưới	Giới hạn trên	Độ rộng
Bootstrap	31.8	31.7	31.9	0.141
EL	31.8	31.7	31.9	0.144

Bảng 10: So sánh khoảng tin cậy 95% giữa phương pháp Bootstrap và Empirical Likelihood

Nhận xét:

- Cả hai phương pháp Bootstrap và Empirical Likelihood đều cho ước lượng trung bình BMI tương đương nhau.
- Khoảng tin cậy 95% thu được từ hai phương pháp có giới hạn dưới và giới hạn trên rất gần nhau.
- Độ rộng khoảng tin cậy của hai phương pháp gần như tương đương, cho thấy mức độ chính xác của ước lượng là tương đồng.

Kết luận: Kết quả cho thấy hai phương pháp phi tham số Bootstrap và Empirical Likelihood đưa ra các ước lượng nhất quán cho BMI trung bình, qua đó củng cố độ tin cậy của kết luận thống kê. Đồng thời cả hai phương pháp đều có thể đưa ra cùng một kết luận là là BMI trung bình của người mắc tiểu đường (`Diabetes_binary = 1`) nằm trong nhóm phân loại **Béo phì cấp độ 1** theo WHO.

3.3.4 So sánh BMI giữa nhóm không tiểu đường và có tiểu đường (`Diabetes_binary = 0` và `Diabetes_binary = 1`)

2.5%	97.5%
3.987042	4.140141

Biểu đồ chênh lệch Bootstrap:

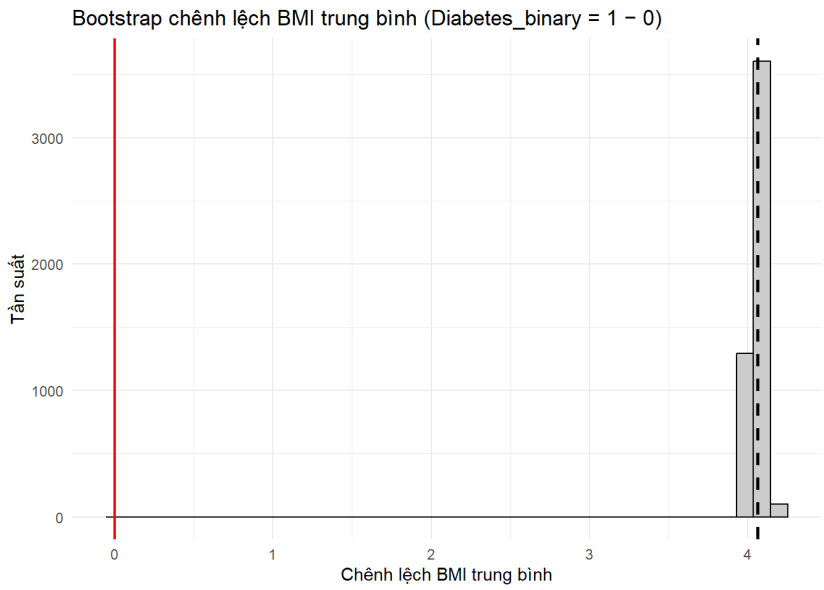

Hình 9: Biểu đồ phân phối bootstrap chênh lệch BMI trung bình (`Diabetes_binary=1-0`)

Nhận xét:

- Phân phối tập trung quanh giá trị chênh lệch dương và nằm hoàn toàn xa mốc 0, cho thấy BMI trung bình của nhóm có tiểu đường cao hơn rõ rệt so với nhóm không tiểu đường.
- Chênh lệch BMI trung bình giữa nhóm mắc tiểu đường và nhóm không tiểu đường là 4.06.
- Khoảng tin cậy bootstrap 95% cho chênh lệch này là [3.99; 4.14].
- Khoảng tin cậy bootstrap 95% không chứa giá trị 0, cung cấp bằng chứng về sự khác biệt có ý nghĩa thống kê giữa hai nhóm.

3.4 So sánh sự khác biệt giữa 2 cách mã hóa biến tiểu đường

Trường hợp	Trung bình	Giới hạn dưới	Giới hạn trên
Biến gốc (`Diabetes_012 = 2`)	31.94	31.87	32.02
Gộp biến (`Diabetes_binary = 1`)	31.80	31.73	31.87

Bảng 11: So sánh khoảng tin cậy 95% cho BMI trung bình theo hai cách mã hóa biến tiểu đường

Tiến hành vẽ biểu đồ so sánh sự chênh lệch khoảng tin cậy 95% theo BMI trung bình của hai cách mã hóa biến:

Biểu đồ so sánh chênh lệch:

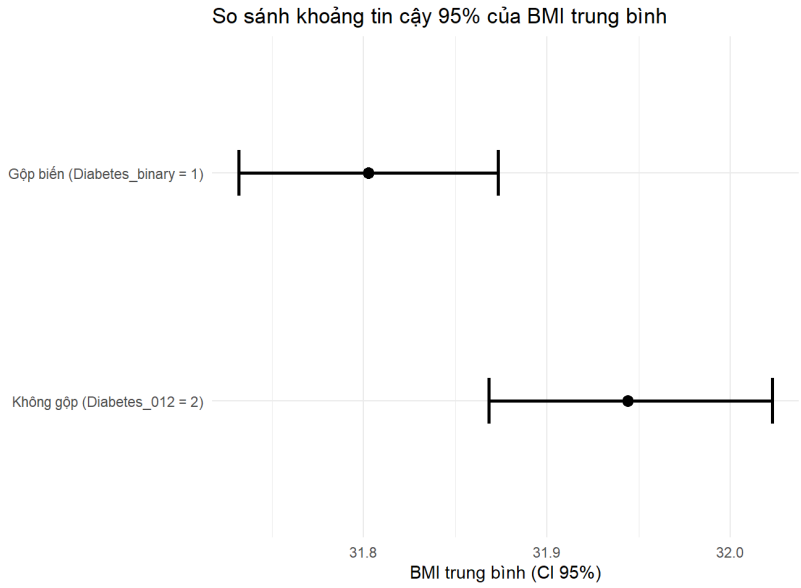

Hình 10: Biểu đồ so sánh chênh lệch CI 95%

Nhận xét: Biểu đồ cho thấy BMI trung bình của nhóm tiểu đường trong trường hợp giữ nguyên biến gốc (Diabetes_012 = 2) cao hơn so với trường hợp gộp biến (Diabetes_binary = 1).

Kết luận: Việc gộp nhóm tiền tiểu đường vào nhóm mắc tiểu đường làm giảm giá trị ước lượng BMI trung bình, do đó mức chênh lệch so với nhóm không tiểu đường trở nên nhỏ hơn. Tuy nhiên, trong cả hai trường hợp, khoảng tin cậy 95% đều tương đối hẹp, cho thấy kết luận về sự khác biệt BMI giữa các nhóm là ổn định và nhất quán.

3.5 Tổng hợp kết quả theo câu hỏi nghiên cứu

3.5.1 Câu hỏi 1: Khoảng tin cậy 95% cho BMI trung bình của nhóm có tiểu đường

Trường hợp 1: Sử dụng biến gốc

Khi chỉ xét nhóm tiểu đường thực sự (Diabetes_012 = 2), kết quả từ cả hai phương pháp Bootstrap và Empirical Likelihood cho thấy BMI trung bình của nhóm này nằm trong một khoảng tin cậy hẹp với độ tin cậy 95%. Khoảng tin cậy thu được phản ánh rằng BMI trung bình của người mắc tiểu đường ở mức cao, tương ứng với nhóm béo phì cấp độ 1 theo phân loại của WHO, và ước lượng này là ổn định ngay cả khi không giả định phân phối chuẩn của dữ liệu BMI.

Trường hợp 2: Gộp biến

Khi gộp nhóm tiền tiểu đường và tiểu đường thành nhóm có tiểu đường, BMI trung bình của nhóm này có xu hướng thấp hơn nhẹ so với trường hợp không gộp biến. Tuy nhiên, khoảng tin cậy 95% vẫn nằm trong vùng BMI cao, cho thấy ngay cả khi mở rộng định nghĩa nhóm bệnh, BMI trung bình của nhóm có tiểu đường vẫn thuộc phân loại **béo phì cấp độ 1** theo WHO.

Kết luận chung

- Kết quả phân tích cho thấy, bất kể cách định nghĩa biến tiểu đường (sử dụng biến gốc Diabetes_012 hay biến gộp Diabetes_binary), BMI trung bình của nhóm mắc tiểu đường đều được ước lượng trong một khoảng tin cậy 95% hẹp và ổn định.
- Trong cả hai trường hợp, BMI trung bình của người mắc tiểu đường nằm ở mức cao, thuộc nhóm thừa cân – béo phì cấp độ 1 theo phân loại của WHO.
- Điều này cho thấy kết luận về BMI trung bình của người mắc tiểu đường không nhạy cảm với cách mã hóa biến tiểu đường.

3.5.2 Câu hỏi 2: So sánh BMI giữa người có và không mắc tiểu đường

Trường hợp 1: Sử dụng biến gốc

So sánh Bootstrap cho chênh lệch BMI trung bình giữa nhóm không tiểu đường (Diabetes_012 = 0) và nhóm tiểu đường (Diabetes_012 = 2) cho thấy khoảng tin cậy 95% của chênh lệch không chứa giá trị 0. Điều này cung cấp bằng chứng thống kê rõ ràng rằng BMI trung bình của người mắc tiểu đường cao hơn đáng kể so với người không mắc tiểu đường.

Trường hợp 2: Gộp biến

Khi sử dụng biến gộp, so sánh giữa nhóm có tiểu đường (Diabetes_binary = 1) và nhóm không tiểu đường (Diabetes_binary = 0) tiếp tục cho thấy khoảng tin cậy Bootstrap 95% cho chênh lệch BMI trung bình không chứa giá trị 0. Kết quả này nhất quán với trường hợp không gộp biến, khẳng định rằng BMI trung bình của nhóm có tiểu đường cao hơn rõ rệt so với nhóm không tiểu đường.

Kết luận chung

- Phân tích so sánh BMI giữa nhóm mắc tiểu đường và nhóm không mắc tiểu đường cho thấy sự khác biệt rõ rệt và nhất quán trong cả hai cách định nghĩa biến tiểu đường.
- Trong mọi trường hợp, khoảng tin cậy Bootstrap 95% cho chênh lệch BMI trung bình giữa hai nhóm đều không chứa giá trị 0, cho thấy BMI của người mắc tiểu đường cao hơn đáng kể so với người không mắc tiểu đường.

Do đó, có thể kết luận rằng sự khác biệt BMI giữa hai nhóm không nhạy cảm với cách mã hóa biến tiểu đường.

4 Kiểm định giả thuyết thống kê

Mục tiêu của mục là xây dựng và kiểm định các giả thuyết thống kê nhằm đánh giá mối liên hệ giữa các biến giải thích và biến mục tiêu `Diabetes_binary`. Do các biến trong bộ dữ liệu có bản chất khác nhau, các kiểm định được lựa chọn sao cho phù hợp với từng loại biến, bao gồm:

- **Biến phân loại nhị phân**: sử dụng kiểm định Chi-bình phương, bao gồm các biến:
  - `Sex`, `HighBP`, `HighChol`, `CholCheck`, `Smoker`
  - `PhysActivity`, `DiffWalk`, `Stroke`, `HeartDiseaseorAttack`
  - `Fruits`, `Veggies`, `AnyHealthcare`, `NoDocbcCost`, `HvyAlcoholConsump`
- **Biến định lượng**: sử dụng kiểm định hoán vị hai phía, bao gồm các biến:
  - `BMI`, `MentHlth`, `PhysHlth`
- **Biến thứ bậc**: sử dụng kiểm định hoán vị hai phía, bao gồm các biến:
  - `Age`, `GenHlth`, `Income`, `Education`

Việc kết hợp nhiều loại kiểm định cho phép đánh giá toàn diện ảnh hưởng của các biến độc lập đến tình trạng mắc tiểu đường.

4.1 Kiểm định Chi-bình phương

Kiểm định Chi-bình phương được sử dụng để đánh giá mối liên hệ giữa một biến phân loại nhị phân và biến mục tiêu `Diabetes_binary`, vốn cũng là biến nhị phân. Giả thuyết kiểm định được phát biểu như sau:

H_0 : Biến nhị phân X độc lập với `Diabetes_binary`.

H_1 : Biến nhị phân X có mối liên hệ với `Diabetes_binary`.

Nếu p-value nhỏ hơn mức ý nghĩa $\alpha = 0.05$, giả thuyết không H_0 bị bác bỏ, cho thấy biến đang xét có ảnh hưởng thống kê đến tình trạng mắc tiểu đường.

Variable <chr>	Chi_square <dbl>	df <int>	p_value <dbl>	Conclusion <chr>
HighBP	18537.57386	1	0.000000e+00	Bác bỏ H0
HighChol	11217.00393	1	0.000000e+00	Bác bỏ H0
CholCheck	1167.84917	1	5.924497e-256	Bác bỏ H0
Smoker	999.41476	1	2.406995e-219	Bác bỏ H0
Stroke	2784.70393	1	0.000000e+00	Bác bỏ H0
HeartDiseaseorAttack	7939.89047	1	0.000000e+00	Bác bỏ H0
PhysActivity	3737.44880	1	0.000000e+00	Bác bỏ H0
Fruits	449.12274	1	1.119518e-99	Bác bỏ H0
Veggies	889.21842	1	2.165824e-195	Bác bỏ H0
HvyAlcoholConsump	814.37395	1	4.045205e-179	Bác bỏ H0

Variable <chr>	Chi_square <dbl>	df <int>	p_value <dbl>	Conclusion <chr>
AnyHealthcare	50.10671	1	1.456086e-12	Bác bỏ H0
NoDocbcCost	366.42930	1	1.121130e-81	Bác bỏ H0
DiffWalk	12518.18746	1	0.000000e+00	Bác bỏ H0
Sex	222.18491	1	3.018623e-50	Bác bỏ H0

4.2 Kiểm định hoán vị

Kiểm định hoán vị hai phía được sử dụng để so sánh phân phối (hoặc giá trị trung bình) của một biến định lượng hoặc biến thứ bậc giữa hai nhóm của biến mục tiêu `Diabetes_binary`.

Do không yêu cầu giả định về dạng phân phối của dữ liệu, kiểm định hoán vị đặc biệt phù hợp với các biến có phân phối lệch hoặc không tuân theo phân phối chuẩn.

Giả thuyết kiểm định chung cho biến định lượng được phát biểu như sau:

H_0 : Phân phối của biến X là như nhau giữa hai nhóm `Diabetes_binary`.

H_1 : Phân phối của biến X khác nhau giữa hai nhóm `Diabetes_binary`.

Giả thuyết kiểm định chung cho biến thứ bậc được phát biểu như sau:

H_0 : Phân phối (về vị trí trung tâm) của X là như nhau giữa hai nhóm `Diabetes_binary`.

H_1 : Phân phối (về vị trí trung tâm) của X khác nhau giữa hai nhóm `Diabetes_binary`.

```{r}
bmi_perm <- perm_fun(.data = df,
                     x = BMI,
                     g = Diabetes_binary,
                     sign_grp = c(1, -1),
                     R = 1000)
bmi_perm$p_val
```

```
[1] 0
```

Variable <chr>	Mean_Diff <dbl>	p_value <dbl>	Conclusion <chr>
MentHlth	-1.525291	0	Bác bỏ H0
PhysHlth	-4.186001	0	Bác bỏ H0

Variable <chr>	Mean_Diff <dbl>	p_value <dbl>	Conclusion <chr>
Age	-1.5582393	0	Bác bỏ H0
GenHlth	-0.8820557	0	Bác bỏ H0
Education	0.3565980	0	Bác bỏ H0
Income	0.9822332	0	Bác bỏ H0

4.3 Tổng kết

Với cỡ mẫu lớn của bộ dữ liệu, phần lớn các kiểm định giả thuyết đều dẫn đến việc bác bỏ giả thuyết không H_0. Tuy nhiên, kết quả này chỉ cho thấy sự tồn tại của khác biệt có ý nghĩa thống kê giữa các nhóm, và không đồng nghĩa với việc tất cả các biến đều có mức độ đóng góp lớn hoặc mang ý nghĩa thực tiễn cao đối với biến mục tiêu.

Do đó, các kiểm định giả thuyết trong phần này được sử dụng như một bước tham khảo ban đầu nhằm khám phá mối liên hệ giữa các biến, thay vì làm căn cứ duy nhất cho việc lựa chọn biến. Bên cạnh đó, từ các phân tích thống kê ban đầu có thể rút ra một số nhận xét mang tính mô tả:

- Tình trạng tiểu đường có mối liên hệ với nhiều khía cạnh khác nhau, bao gồm chỉ số sức khỏe, hành vi lối sống, chức năng thể chất và điều kiện kinh tế – xã hội, cho thấy đây là một bệnh lý mang tính đa chiều.
- Nhóm người mắc tiểu đường có xu hướng tự đánh giá sức khỏe tổng quát, sức khỏe tinh thần và sức khỏe thể chất kém hơn, đồng thời có chỉ số BMI cao hơn, gợi ý rằng các biến như `BMI` và `GenHlth` có tiềm năng cao trong mô hình dự báo.
- Tuổi tác có mối liên hệ dương với nguy cơ mắc tiểu đường, khi tỷ lệ mắc bệnh tăng dần theo các nhóm tuổi cao hơn.
- Nhóm không mắc tiểu đường có xu hướng đạt trình độ học vấn cao hơn.

- Tỷ lệ mắc tiểu đường có xu hướng cao hơn ở các nhóm thu nhập thấp.

5 Tiêu chí chọn biến cho mô hình

Sau khi thực hiện các kiểm định giả thuyết, các biến được tiếp tục đánh giá và sàng lọc dựa trên nhiều tiêu chí khác nhau nhằm lựa chọn tập biến đầu vào phù hợp cho mô hình dự báo.

5.1 Chọn biến từ tương quan Pearson giữa các biến với biến mục tiêu `Diabetes_binary`

Hệ số tương quan Pearson được sử dụng để đo lường mức độ liên hệ tuyến tính giữa các biến định lượng và biến mục tiêu.

Các biến có giá trị tương quan lớn về độ lớn (theo giá trị tuyệt đối) được xem là có tiềm năng đóng góp vào mô hình.

Với ngưỡng lựa chọn $|\rho| > 0.05$, phương pháp này giúp hạn chế việc loại bỏ sớm các biến có mức độ liên hệ yếu nhưng tiềm tàng, đồng thời tránh giữ lại quá nhiều biến nhiễu. Kết quả cho thấy có 17 biến thỏa điều kiện và được giữ lại cho các bước phân tích tiếp theo.

variable <chr>	correlation <dbl>	abs_correlation <dbl>
GenHlth	0.30078467	0.30078467
HighBP	0.27033414	0.27033414
BMI	0.22385070	0.22385070
DiffWalk	0.22215489	0.22215489
HighChol	0.21028966	0.21028966
Age	0.18589120	0.18589120
HeartDiseaseorAttack	0.17693331	0.17693331
PhysHlth	0.17494838	0.17494838
Income	-0.17279398	0.17279398
Education	-0.13180338	0.13180338

variable <chr>	correlation <dbl>	abs_correlation <dbl>
PhysActivity	-0.12139187	0.12139187
Stroke	0.10479970	0.10479970
MentHlth	0.07497090	0.07497090
CholCheck	0.06787860	0.06787860
Smoker	0.06277766	0.06277766
Veggies	-0.05921920	0.05921920
HvyAlcoholConsump	-0.05668248	0.05668248

5.2 Chọn biến phân loại nhị phân từ Chi-bình phương

Đối với các biến phân loại nhị phân, kết quả kiểm định Chi-bình phương còn được sử dụng để đo lường mức độ liên hệ giữa các biến với biến mục tiêu `Diabetes_binary`.

Cần lưu ý rằng trong bối cảnh này, kiểm định Chi-bình phương không được sử dụng với mục đích suy luận thống kê nhằm bác bỏ hay chấp nhận giả thuyết độc lập thông qua p-value, mà đóng vai trò như một thước đo định lượng phản ánh cường độ liên hệ giữa biến phân loại nhị phân và biến mục tiêu.

Cụ thể, các biến được sắp xếp theo thứ tự giảm dần của giá trị Chi-bình phương. Những biến có giá trị Chi-bình phương lớn hơn cho thấy mức độ khác biệt phân phối giữa hai nhóm `Diabetes_binary` rõ rệt hơn, từ đó được xem là có tiềm năng đóng góp cao hơn cho mô hình dự báo.

Do đó, tập biến phân loại nhị phân được lựa chọn trong mục nên được hiểu như một tập biến có giá trị hỗ trợ dự báo, và sẽ được đưa vào mô hình chứ không phải bằng chứng cho mối quan hệ nhân quả hay tác động độc lập của từng biến đối với nguy cơ mắc tiểu đường.

Variable <chr>	Chi_square <dbl>	df <int>	p_value <dbl>	Conclusion <chr>
HighBP	18537.5739	1	0.000000e+00	Bác bỏ H0
DiffWalk	12518.1875	1	0.000000e+00	Bác bỏ H0
HighChol	11217.0039	1	0.000000e+00	Bác bỏ H0
HeartDiseaseorAttack	7939.8905	1	0.000000e+00	Bác bỏ H0
PhysActivity	3737.4488	1	0.000000e+00	Bác bỏ H0
Stroke	2784.7039	1	0.000000e+00	Bác bỏ H0
CholCheck	1167.8492	1	5.924497e-256	Bác bỏ H0
Smoker	999.4148	1	2.406995e-219	Bác bỏ H0
Veggies	889.2184	1	2.165824e-195	Bác bỏ H0
HvyAlcoholConsump	814.3739	1	4.045205e-179	Bác bỏ H0

5.3 Chọn biến từ Information Value (IV) và Weight of Evidence (WOE)

5.3.1 Weight of Evidence (WOE)

WOE là phép biến đổi các biến giải thích theo từng nhóm (bins), dựa trên tỉ lệ quan sát của hai lớp biến mục tiêu (mắc và không mắc tiểu đường):

$$\text{WOE}_i = \ln\left(\frac{\%\text{Mắc tiểu đường}_i}{\%\text{Không mắc tiểu đường}_i}\right)$$

WOE mang ý nghĩa đo lường mức độ "bằng chứng"của từng nhóm giá trị đối với khả năng mắc bệnh. WOE dương cho thấy nhóm đó có xu hướng liên quan đến tình trạng mắc tiểu đường, trong khi WOE âm cho thấy xu hướng ngược lại.

5.3.2 Information Value (IV)

Information Value là thước đo tổng hợp mức độ phân tách hai lớp của biến mục tiêu mà một biến giải thích mang lại, được tính theo công thức:

$$\text{IV} = \sum_i \left(\%\text{Mắc tiểu đường}_i - \%\text{Không mắc tiểu đường}_i\right) \times \text{WOE}_i$$

Giá trị IV được diễn giải như sau:

- $\text{IV} < 0.02$: biến hầu như không có giá trị dự báo;
- $0.02 \leq \text{IV} < 0.10$: khả năng dự báo yếu;
- $0.10 \leq \text{IV} < 0.30$: khả năng dự báo trung bình;
- $0.30 \leq \text{IV} < 0.50$: khả năng dự báo mạnh;
- $\text{IV} \geq 0.50$: khả năng dự báo quá mạnh, có thể tiềm ẩn rủi ro overfitting.

Với ngưỡng lựa chọn $\text{IV} > 0.10$, tương ứng với mức khả năng dự báo từ trung bình trở lên, đã xác định được 11 biến giải thích có đóng góp đáng kể trong việc phân biệt tình trạng mắc và không mắc tiểu đường.

	Variable <chr>	IV <dbl>
14	GenHlth	0.7488573
1	HighBP	0.5746289
4	BMI	0.4436996
19	Age	0.3620018
2	HighChol	0.3354728
17	DiffWalk	0.2981389
21	Income	0.2284645
16	PhysHlth	0.1996290
7	HeartDiseaseorAttack	0.1781584
20	Education	0.1278206
8	PhysActivity	0.1003726

5.4 Tổng kết

Ta có được bảng tổng kết như sau:

Bảng 12: Tổng hợp 21 biến ban đầu và kết quả lựa chọn theo các phương pháp sàng lọc

Biến	**Tương quan Pearson**	**Chi-bình phương**	**IV/WOE**
HighBP	x	x	x
HighChol	x	x	x
CholCheck	x	x	
BMI	x		x
Smoker	x	x	
Stroke	x	x	
HeartDiseaseorAttack	x	x	x
PhysActivity	x	x	x
Fruits			
Veggies	x	x	
HvyAlcoholConsump	x	x	
AnyHealthcare			
NoDocbcCost			
GenHlth	x		x
MentHlth	x		
PhysHlth	x		x
DiffWalk	x	x	x
Sex			
Age	x		x
Education	x		x
Income	x		x
Tổng	**17**	**10**	**11**

Dựa trên kết quả phân tích thăm dò dữ liệu (EDA) và các phương pháp sàng lọc biến theo nhiều góc độ khác nhau, 11 biến giải thích được lựa chọn để sử dụng trong các mô hình dự báo tình trạng tiểu đường, bao gồm:

- `GenHlth`
- `HighBP`
- `BMI`
- `Age`
- `HighChol`
- `DiffWalk`
- `Income`
- `PhysHlth`
- `HeartDiseaseorAttack`
- `Education`
- `PhysActivity`

Cần lưu ý rằng các phương pháp lựa chọn biến được sử dụng trong bài, bao gồm phân tích tương quan, kiểm định Chi-square và IV/WOE, chủ yếu nhằm mục đích sàng lọc biến theo hướng dự báo, hỗ trợ cho việc xây dựng mô hình. Do đó, các biến được lựa chọn không nên được diễn giải như bằng chứng cho mối quan hệ nhân quả hay tác động độc lập đến nguy cơ mắc tiểu đường.

6 Xây dựng mô hình hồi quy Logistic và mô hình Multinomal Logistic

6.1 Mục tiêu

Mục tiêu của việc xây dựng mô hình phân loại trong dự án này là sử dụng các chỉ số sức khỏe cần thiết và có ý nghĩa thống kê, đồng thời tối ưu hóa số lượng biến đầu vào, nhằm phân loại chính xác tình trạng tiểu đường của bệnh nhân. Mô hình được thiết kế để dự đoán và phân loại bệnh nhân vào ba trạng thái sức khỏe sau:

- **0**: Không mắc bệnh tiểu đường

- **1**: Giai đoạn tiền tiểu đường
- **2**: Giai đoạn mắc bệnh tiểu đường

Để đánh giá khả năng chẩn đoán của mô hình trong các kịch bản khác nhau, nhóm tiến hành xây dựng và phân tích mô hình trên hai trường hợp cụ thể.

Thứ nhất, mô hình được xây dựng để phân loại bệnh nhân thành hai nhóm, bao gồm nhóm không mắc bệnh tiểu đường và nhóm mắc bệnh tiểu đường, trong đó các trường hợp tiền tiểu đường và tiểu đường được gộp chung thành một nhóm bệnh. Trường hợp này nhằm đánh giá khả năng sàng lọc và phát hiện bệnh ở mức tổng quát.

Thứ hai, mô hình được mở rộng để phân loại bệnh nhân thành ba nhóm riêng biệt, tương ứng với không mắc tiểu đường, tiền tiểu đường và mắc tiểu đường. Trường hợp này cho phép đánh giá chi tiết hơn khả năng phân biệt giữa các mức độ tiến triển của bệnh.

Bên cạnh đó, nhằm nâng cao hiệu quả ứng dụng của các phương pháp được đề xuất, nhóm tiến hành áp dụng các kỹ thuật cân bằng dữ liệu để điều chỉnh sự mất cân đối về số lượng quan sát giữa các nhóm trong biến phản hồi. Trên cơ sở dữ liệu đã được cân bằng, các mô hình phân loại tiếp tục được xây dựng và huấn luyện để phục vụ cho bài toán chẩn đoán bệnh. Cuối cùng, nhóm thực hiện so sánh và đánh giá hiệu quả của các mô hình trước và sau khi cân bằng dữ liệu, từ đó đưa ra nhận xét về mức độ cải thiện và tính phù hợp của từng mô hình trong bài toán chẩn đoán bệnh tiểu đường.

6.2 Mô hình hồi quy logistic

Mô hình hồi quy logistic có dạng như sau:

$$\log\left(\frac{p(\boldsymbol{x})}{1-p(\boldsymbol{x})}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p \tag{1}$$

Phần lớn các biến được sử dụng trong quá trình xây dựng mô hình là các biến định tính, do đó việc chuyển đổi các biến này sang dạng factor là cần thiết. Nhóm đã tiến hành chuyển đổi các biến định tính tham gia vào mô hình, bao gồm HighBP, HighChol, CholCheck, Smoker, Stroke, HeartDiseaseorAttack, PhysActivity, Fruits, Veggies, HvyAlcoholConsump, AnyHealthcare, NoDocbcCost, DiffWalk và Sex, sang dạng factor nhằm phản ánh đúng bản chất phân loại của dữ liệu. Các biến có thứ bậc tự nhiên như GenHlth, Age, Education và

Income được mã hóa dưới dạng ordered factor để bảo toàn mối quan hệ thứ tự giữa các mức. Sau đó, dữ liệu được chia ngẫu nhiên thành tập train và tập test theo tỷ lệ 8:2 nhằm đảm bảo việc đánh giá mô hình được thực hiện một cách khách quan và chính xác.

6.2.1 Ước lượng mô hình trên tập dữ liệu gốc

Nhóm tiến hành xây dựng mô hình hồi quy logistic với Diabetes_binary là biến phụ thuộc và tất cả các biến còn lại trong bộ dữ liệu được sử dụng làm biến giải thích, kết quả ước lượng được trình bày trong bảng 13.

Bảng 13: Hệ số hồi quy của mô hình hồi quy logistic 0

Biến	**Estimate**	**Std. Error**	**z-value**	**Pr(> |z|)**
(Intercept)	-4.2595	0.0526	-80.931	$< 2 \times 10^{-16}$
HighBP1	0.6701	0.0091	74.031	$< 2 \times 10^{-16}$
HighChol1	0.5605	0.0087	64.521	$< 2 \times 10^{-16}$
CholCheck1	1.1580	0.0355	32.664	$< 2 \times 10^{-16}$
BMI	0.0688	0.0007	96.296	$< 2 \times 10^{-16}$
Smoker1	-0.0253	0.0087	-2.899	0.00374
Stroke1	0.1727	0.0189	9.155	$< 2 \times 10^{-16}$
HeartDiseaseorAttack1	0.2575	0.0131	19.606	$< 2 \times 10^{-16}$
PhysActivity1	-0.0384	0.0098	-3.929	8.53×10^{-5}
Fruits1	-0.0282	0.0090	-3.117	0.00183
Veggies1	-0.0431	0.0107	-4.017	5.89×10^{-5}
HvyAlcoholConsump1	-0.6432	0.0217	-29.598	$< 2 \times 10^{-16}$
AnyHealthcare1	0.0580	0.0214	2.707	0.00679
NoDocbcCost1	0.1072	0.0156	6.863	6.75×10^{-12}
GenHlth.L	1.5364	0.0183	83.879	$< 2 \times 10^{-16}$
GenHlth.Q	-0.3684	0.0137	-26.870	$< 2 \times 10^{-16}$
GenHlth.C	-0.0903	0.0107	-8.471	$< 2 \times 10^{-16}$
GenHlth^4	0.0131	0.0082	1.595	0.11065
MentHlth	-0.0015	0.0006	-2.533	0.01131
PhysHlth	-0.0026	0.0006	-4.587	4.50×10^{-6}
DiffWalk1	0.1156	0.0119	9.694	$< 2 \times 10^{-16}$
Sex1	0.2692	0.0088	30.546	$< 2 \times 10^{-16}$
Age.L	2.3384	0.0343	68.256	$< 2 \times 10^{-16}$
Age.Q	-0.6008	0.0318	-18.882	$< 2 \times 10^{-16}$
Age.C	-0.2247	0.0298	-7.531	5.03×10^{-14}
Age^4	-0.0264	0.0288	-0.919	0.35812
Age^5	-0.1370	0.0275	-4.975	6.52×10^{-7}
Age^6	0.0419	0.0259	1.618	0.10565
Age^7	0.0773	0.0244	3.172	0.00151
Age^8	-0.0579	0.0226	-2.566	0.01028
Age^9	0.0803	0.0204	3.946	7.95×10^{-5}
Age^{10}	-0.1051	0.0181	-5.794	6.87×10^{-9}
Age^{11}	0.0817	0.0164	4.985	6.21×10^{-7}
Age^{12}	0.0269	0.0145	1.849	0.06446
Education.L	-0.0856	0.0874	-0.980	0.32721
Education.Q	-0.1528	0.0795	-1.923	0.05446
Education.C	0.1471	0.0565	2.605	0.00918
Education^4	-0.1490	0.0332	-4.491	7.07×10^{-6}
Education^5	-0.0002	0.0186	-0.009	0.99242
Income.L	-0.4204	0.0167	-25.155	$< 2 \times 10^{-16}$
Income.Q	-0.0813	0.0145	-5.621	1.90×10^{-8}
Income.C	-0.0268	0.0139	-1.926	0.05406
Income^4	-0.0291	0.0139	-2.089	0.03669
Income^5	0.0009	0.0137	0.067	0.94692
Income^6	-0.0271	0.0133	-2.045	0.04085
Income^7	0.0185	0.0130	1.424	0.15444

Nhận xét: Ta thấy rằng đa số các biến giải thích trong mô hình đều có ý nghĩa thống kê cao, thể hiện qua giá trị p-value rất nhỏ (phần lớn $p < 0.001$). Điều này cho thấy các biến như *HighBP*, *HighChol*, *CholCheck*, *BMI*, *GenHlth*, *Age*, *HeartDiseaseorAttack*, *DiffWalk*, *Sex* và một số thành

phần của biến *Income* có đóng góp đáng kể trong việc phân loại đối tượng mắc và không mắc tiểu đường ở mức ý nghĩa $\alpha = 5\%$. Tuy nhiên, mô hình cũng cho thấy một số biến không đạt ý nghĩa thống kê, bao gồm *Fruits*, *MentHlth*, một số bậc cao của *Age*, phần lớn các mức của *Education*, và một số thành phần của *Income* (như *Income.C*, $Income^4$ – $Income^7$). Việc giữ lại các biến này cần được cân nhắc thêm.

Về ý nghĩa của mỗi ước lượng, ta sẽ tính tỷ lệ cược - odds cho mỗi biến trong bảng 14.

Bảng 14: Tỷ lệ cược (Odds Ratio) của các biến trong mô hình hồi quy logistic

Biến	**Tỷ lệ cược**
(Intercept)	0.0141
HighBP1	1.9545
HighChol1	1.7516
CholCheck1	3.1836
BMI	1.0712
Smoker1	0.9750
Stroke1	1.1885
HeartDiseaseorAttack1	1.2936
PhysActivity1	0.9623
Fruits1	0.9722
Veggies1	0.9578
HvyAlcoholConsump1	0.5256
AnyHealthcare1	1.0597
NoDocbcCost1	1.1131
GenHlth.L	4.6477
GenHlth.Q	0.6919
GenHlth.C	0.9137
$GenHlth^4$	1.0131
MentHlth	0.9985
PhysHlth	0.9974
DiffWalk1	1.1225
Sex1	1.3089

Biến	**Tỷ lệ cược**
Age.L	10.3646
Age.Q	0.5484
Age.C	0.7988
Age^4	0.9739
Age^5	0.8720
Age^6	1.0428
Age^7	1.0803
Age^8	0.9438
Age^9	1.0836
Age^{10}	0.9003
Age^{11}	1.0852
Age^{12}	1.0272
Education.L	0.9180
Education.Q	0.8583
Education.C	1.1585
$Education^4$	0.8616
$Education^5$	0.9998
Income.L	0.6568
Income.Q	0.9219
Income.C	0.9735
$Income^4$	0.9713
$Income^5$	1.0009
$Income^6$	0.9733
$Income^7$	1.0186

Nhận xét:

Đối với các biến có tỷ lệ cược lớn hơn 1 (Odds Ratio > 1):

- **HighBP (OR = 1.95):** Cá nhân có huyết áp cao có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 95% so với người không bị cao huyết áp, khi các yếu tố khác được giữ cố định. Điều này cho thấy cao huyết áp là một yếu tố nguy cơ quan trọng và có ảnh hưởng mạnh đến khả năng mắc bệnh tiểu đường.

- **HighChol (OR = 1.75):** Người có cholesterol cao có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 75% so với người không có cholesterol cao, phản ánh mối liên hệ chặt chẽ giữa rối loạn lipid máu và bệnh tiểu đường.

- **CholCheck (OR = 3.18):** Những người đã từng kiểm tra cholesterol có Odds Ratio lớn hơn đáng kể. Kết quả này có thể phản ánh hiện tượng *detection bias*, khi những người có nguy cơ cao hoặc đã có vấn đề sức khỏe thường xuyên kiểm tra y tế hơn.

- **HeartDiseaseorAttack (OR = 1.29):** Người có tiền sử bệnh tim mạch hoặc từng bị nhồi máu cơ tim có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 29%, cho thấy sự đồng mắc phổ biến giữa bệnh tim mạch và các rối loạn chuyển hóa.

- **DiffWalk (OR = 1.12):** Những người gặp khó khăn trong việc đi lại có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 12% so với người không gặp vấn đề vận động, cho thấy mối liên hệ giữa suy giảm chức năng vận động và nguy cơ bệnh lý chuyển hóa.

- **Sex (OR = 1.31):** Giới tính có ảnh hưởng đáng kể đến nguy cơ mắc bệnh tiểu đường; trong đó nhóm được mã hóa là 1 có nguy cơ cao hơn khoảng 31% so với nhóm còn lại.

- **BMI (OR = 1.07):** Khi chỉ số BMI tăng thêm một đơn vị, nguy cơ mắc bệnh tiểu đường tăng khoảng 7%, khẳng định vai trò quan trọng của tình trạng thừa cân – béo phì trong cơ chế hình thành bệnh.

- **GenHlth (OR = 4.65):** Sức khỏe tổng quát có Odds Ratio rất lớn, cho thấy khi mức đánh giá sức khỏe tổng quát kém đi, nguy cơ mắc

bệnh tiểu đường tăng mạnh. Các thành phần bậc cao hơn (bậc hai, ba, bốn) có OR dao động quanh 1, phản ánh mối quan hệ phi tuyến giữa sức khỏe tổng quát và nguy cơ mắc bệnh.

- **Age (OR = 10.36):** Tuổi có Odds Ratio rất lớn, cho thấy nguy cơ mắc bệnh tiểu đường tăng mạnh theo tuổi. Các thành phần đa thức bậc cao hơn có OR dao động quanh 1, cho thấy mối quan hệ giữa tuổi và nguy cơ mắc bệnh là phi tuyến và phức tạp.

Đối với các biến có tỷ lệ cược nhỏ hơn 1 (Odds Ratio $<$ 1):

- **PhysActivity (OR = 0.96):** Những người có tham gia hoạt động thể chất có nguy cơ mắc bệnh tiểu đường thấp hơn khoảng 4% so với những người không hoạt động thể chất, cho thấy vai trò bảo vệ nhẹ của vận động đối với sức khỏe chuyển hóa.

- **HvyAlcoholConsump (OR = 0.53):** Nhóm tiêu thụ rượu ở mức cao có Odds Ratio nhỏ hơn 1. Tuy nhiên, kết quả này cần được cân nhắc kỹ do khả năng tồn tại các yếu tố gây nhiễu hoặc sai lệch trong khai báo hành vi uống rượu.

- **Fruits và Veggies (OR xấp xỉ 1):** Việc tiêu thụ trái cây và rau xanh cho thấy xu hướng làm giảm nhẹ nguy cơ mắc bệnh tiểu đường, tuy nhiên mức độ ảnh hưởng không mạnh khi đã kiểm soát các yếu tố khác trong mô hình.

- **Income (OR = 0.66):** Thu nhập có Odds Ratio nhỏ hơn 1, cho thấy thu nhập cao hơn có xu hướng làm giảm nguy cơ mắc bệnh tiểu đường. Các thành phần bậc cao hơn có OR gần 1, phản ánh mối quan hệ phi tuyến giữa thu nhập và nguy cơ bệnh.

- **Education:** Các thành phần của biến Education có Odds Ratio dao động quanh 1, cho thấy trình độ học vấn không có ảnh hưởng mạnh và nhất quán đến nguy cơ mắc bệnh tiểu đường khi đã kiểm soát các yếu tố sức khỏe và nhân khẩu học khác.

Nhìn chung, các yếu tố liên quan trực tiếp đến tình trạng sức khỏe cá nhân như huyết áp, cholesterol, bệnh tim mạch, BMI và tuổi tác có ảnh hưởng mạnh và rõ rệt hơn đến nguy cơ mắc bệnh tiểu đường so với các yếu tố lối sống và kinh tế xã hội. Kết quả cũng cho thấy mối quan hệ phi tuyến đáng kể giữa tuổi, sức khỏe tổng quát và nguy cơ mắc bệnh tiểu đường.

6.2.2 Tiên đoán mô hình trên tập dữ liệu gốc

Dự đoán mô hình với ngưỡng phân loại 0.5 trên tập test cho thấy độ chính xác đạt 73.41%. Kết quả ma trận nhầm lẫn của mô hình dự đoán được trình bày trong bảng 15.

Bảng 15: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**
0	31258	1960
1	11530	5988

Nhận xét: Do dữ liệu mất cân bằng khi nhóm không mắc bệnh chiếm khoảng 84%, mô hình phân loại đúng nhóm không mắc tiểu đường với tỷ lệ rất cao, nhưng khả năng phát hiện các trường hợp mắc tiểu đường thấp. Nhìn chung, mô hình có xu hướng thiên mạnh về lớp đa số và chưa phù hợp cho mục tiêu sàng lọc bệnh tiểu đường; do đó, cần xem xét áp dụng các kỹ thuật xử lý mất cân bằng dữ liệu hoặc điều chỉnh ngưỡng phân loại trong các phân tích tiếp theo.

Dự đoán mô hình với ngưỡng phân loại được điều chỉnh xuống 0.3 trên tập test cho thấy độ chính xác đạt 58.75%, không vượt trội so với chiến lược dự đoán theo lớp đa số.

So với ngưỡng phân loại 0.5, việc giảm ngưỡng dự đoán đã làm giảm độ chính xác tổng thể, nhưng đồng thời cải thiện khả năng nhận diện lớp thiểu số, giúp mô hình cân bằng tốt hơn giữa hai lớp. Kết quả ma trận nhầm lẫn của mô hình dự đoán được trình bày trong bảng 16.

Bảng 16: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**
0	22494	635
1	20294	7313

Nhận xét: Nhìn chung, Việc hạ ngưỡng phân loại xuống 0.3 giúp tăng đáng kể khả năng phát hiện các trường hợp tiểu đường, tuy nhiên phải đánh

đổi bằng sự gia tăng mạnh các dự đoán dương tính giả. Trong bối cảnh sàng lọc y tế, ngưỡng này là phù hợp với mục tiêu không để sót người bệnh.

6.2.3 Ước lượng mô hình trên tập dữ liệu cân bằng

Nhằm hạn chế ảnh hưởng của sự mất cân bằng lớp trong dữ liệu, mô hình được ước lượng lại trên tập dữ liệu đã cân bằng để đánh giá chính xác hơn hiệu quả dự đoán. Số lượng quán sát trong mỗi nhóm bệnh sau khi cân bằng dữ liệu như sau:

Bảng 17: Số lượng quan sát trong mỗi nhóm bệnh sau khi cân bằng dữ liệu

Nhóm	**0**	**1**
Số lượng	170915	170915

Ta có kết quả ước lượng trong bảng 18.

Bảng 18: Kết quả ước lượng mô hình hồi quy logistic trên tập dữ liệu cân bằng

Biến	**Ước lượng**	**Sai số chuẩn**	**Giá trị z**	**Pr(> |z|)**
(Intercept)	-6.4892	0.0762	-85.204	$< 2 \times 10^{-16}$
HighBP1	0.7033	0.0092	76.195	$< 2 \times 10^{-16}$
HighChol1	0.5494	0.0088	62.368	$< 2 \times 10^{-16}$
CholCheck1	2.2935	0.0593	38.655	$< 2 \times 10^{-16}$
BMI	0.0753	0.0008	97.243	$< 2 \times 10^{-16}$
Stroke1	-0.2698	0.0202	-13.361	$< 2 \times 10^{-16}$
HeartDiseaseorAttack1	0.0779	0.0136	5.744	$< 10^{-8}$
PhysActivity1	0.0257	0.0100	2.560	0.0105
Fruits1	-0.0401	0.0092	-4.365	$< 10^{-4}$
Veggies1	0.0729	0.0111	6.577	$< 10^{-10}$
HvyAlcoholConsump1	-1.5264	0.0286	-53.354	$< 2 \times 10^{-16}$
AnyHealthcare1	0.4963	0.0259	19.189	$< 2 \times 10^{-16}$
NoDocbcCost1	-0.1074	0.0172	-6.247	$< 10^{-9}$
GenHlth.L	1.9678	0.0201	97.880	$< 2 \times 10^{-16}$
GenHlth.Q	-0.5165	0.0147	-35.079	$< 2 \times 10^{-16}$
MentHlth	-0.0052	0.0006	-8.151	$< 10^{-15}$
PhysHlth	-0.0058	0.0006	-9.511	$< 2 \times 10^{-16}$
DiffWalk1	0.0581	0.0125	4.656	$< 10^{-5}$
Sex1	0.2593	0.0090	28.905	$< 2 \times 10^{-16}$
Age.L	3.2471	0.0439	74.040	$< 2 \times 10^{-16}$
Age.Q	-0.9613	0.0414	-23.199	$< 2 \times 10^{-16}$
Age.C	-0.3446	0.0387	-8.913	$< 2 \times 10^{-16}$
Age^5	-0.1234	0.0349	-3.532	0.0004
Age^6	0.0639	0.0324	1.972	0.0486
Age^7	0.0800	0.0301	2.658	0.0079
Age^8	-0.0796	0.0274	-2.902	0.0037
Age^9	0.1203	0.0241	4.999	$< 10^{-6}$
Age^{10}	-0.1592	0.0206	-7.728	$< 10^{-13}$
Age^{11}	0.1085	0.0179	6.064	$< 10^{-8}$
Age^{12}	0.0625	0.0152	4.114	$< 10^{-4}$
Education.L	0.6336	0.1126	5.626	$< 10^{-7}$
Education.Q	-0.4832	0.1025	-4.713	$< 10^{-5}$
Education^4	-0.1677	0.0408	-4.112	$< 10^{-4}$
Education^5	0.1139	0.0210	5.412	$< 10^{-7}$
Income.L	-0.2837	0.0178	-15.953	$< 2 \times 10^{-16}$
Income.Q	-0.0394	0.0151	-2.613	0.0090
Income^7	0.0357	0.0132	2.696	0.0070

Nhận xét: Ta thấy rằng phần lớn các biến giải thích đều có ý nghĩa thống kê cao, thể hiện qua giá trị p-value rất nhỏ, do đó, các biến dùng để hồi quy cho Diabetes_binary đều có đóng góp đáng kể trong việc phân loại đối tượng mắc và không mắc bệnh tiểu đường ở mức ý nghĩa $\alpha = 5\%$. Tuy nhiên, mô hình vẫn tồn tại một số biến hoặc thành phần không đạt ý nghĩa thống kê, chủ yếu rơi vào một vài bậc cao của biến *Age*, một số thành phần của *Education*, và một số mức của *Income*. Do đó, việc giữ lại các biến này trong mô hình cần được cân nhắc thêm nhằm đơn giản hóa mô hình và nâng cao khả năng diễn giải.

Về ý nghĩa của mỗi ước lượng, ta sẽ tính tỷ lệ cược - odds cho mỗi biến trong bảng 19.

Bảng 19: Tỷ lệ cược (Odds Ratio) của các biến trong mô hình hồi quy logistic

Biến	**Odds Ratio**
(Intercept)	0.0015
HighBP	2.0204
HighChol	1.7322
CholCheck	9.9093
BMI	1.0783
Smoker	0.9956
Stroke	0.7636
HeartDiseaseorAttack	1.0810
PhysActivity	1.0260
Fruits	0.9607
Veggies	1.0756
HvyAlcoholConsump	0.2173
AnyHealthcare	1.6426
NoDocbcCost	0.8982
GenHlth (Linear)	7.1546
GenHlth (Quadratic)	0.5966
GenHlth (Cubic)	1.0188
GenHlth (4th)	0.9919
MentHlth	0.9948
PhysHlth	0.9942
DiffWalk	1.0598
Sex	1.2961
Age (Linear)	25.7160
Age (Quadratic)	0.3824

Biến	**Odds Ratio**
Age (Cubic)	0.7085
Age (4th)	1.0634
Age (5th)	0.8839
Age (6th)	1.0660
Age (7th)	1.0833
Age (8th)	0.9235
Age (9th)	1.1278
Age (10th)	0.8529
Age (11th)	1.1146
Age (12th)	1.0644
Education (Linear)	1.8844
Education (Quadratic)	0.6168
Education (Cubic)	1.1472
Education (4th)	0.8456
Education (5th)	1.1206
Income (Linear)	0.7530
Income (Quadratic)	0.9614
Income (Cubic)	1.0031
Income (4th)	0.9948
Income (5th)	1.0050
Income (6th)	0.9927
Income (7th)	1.0364

Nhận xét:

- *CholCheck*: Ảnh hưởng tăng mạnh, OR tăng từ 3.11 lên 9.91, cho thấy đây là biến vô cùng quan trọng trong việc phân loại.
- Các biến *GenHlth.L* tăng từ OR = 4.64 lên OR = 7.15 và *Age.L* tăng mạnh từ 9.45 lên 25.72, cho thấy đây là những yếu tố quan trọng liên quan đến nguy cơ mắc tiểu đường.

- Các biến *Fruits*, *Veggies*, *MentHlth* và *PhysHlth* duy trì OR xấp xỉ 1 ở cả hai mô hình, cho thấy ảnh hưởng hạn chế đến xác suất mắc tiểu đường.

Kết quả vẫn cho thấy các yếu tố sức khỏe như huyết áp, cholesterol, bệnh về tim mạch, và tuổi tác có ảnh hưởng lớn hơn nhiều đến nguy cơ mắc bệnh tiểu đường so với các yếu tố lối sống và kinh tế.

6.2.4 Tiên đoán mô hình trên tập dữ liệu cân bằng

Dự đoán mô hình với ngưỡng phân loại 0.3 trên tập test, độ chính xác chỉ 59.08% cho thấy mô hình không tối ưu về độ chính xác, nhưng phù hợp cho mục tiêu sàng lọc ban đầu, nơi việc hạn chế bỏ sót ca bệnh quan trọng hơn so với việc giảm số dự đoán mắc bệnh giả. Kết quả ma trận nhầm lẫn của mô hình dự đoán được trình bày trong bảng 20.

Bảng 20: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**
0	22777	751
1	20011	7197

Nhận xét: Mô hình dự đoán được khá nhiều trường hợp mắc bệnh (7 197 ca đúng) nhưng đồng thời tạo ra số lượng lớn dự đoán mắc bệnh giả (20 011 ca), phản ánh xu hướng ưu tiên phát hiện ca bệnh với cái giá phải trả là giảm độ chính xác tổng thể.

6.2.5 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu gốc

Dựa trên kết quả chọn biến ở phần trên, nhóm tiến hành xây dựng mô hình hồi quy logistic với Diabetes_binary là biến phụ thuộc và 11 biến giải thích gồm GenHlth, HighBP, BMI, Age, HighChol, DiffWalk, Income, PhysHlth, HeartDiseaseorAttack, Education và PhysActivity. Kết quả ước lượng được trình bày trong bảng 21.

Bảng 21: Hệ số hồi quy của mô hình hồi quy logistic 2

Biến	**Ước lượng**	**Sai số chuẩn**	**Giá trị z**	**Pr(>|z|)**
(Intercept)	-4.3857	0.0523	-83.932	$< 2 \times 10^{-16}$
GenHlth.L	1.5618	0.0302	51.657	$< 2 \times 10^{-16}$
GenHlth.Q	-0.3447	0.0227	-15.151	$< 2 \times 10^{-16}$
GenHlth.C	-0.0826	0.0174	-4.741	2.13×10^{-6}
GenHlth^4	0.0229	0.0131	1.749	0.0803
HighBP1	0.7003	0.0154	45.372	$< 2 \times 10^{-16}$
BMI	0.0597	0.0010	60.539	$< 2 \times 10^{-16}$
Age.L	2.2658	0.0670	33.831	$< 2 \times 10^{-16}$
Age.Q	-0.6960	0.0635	-10.968	$< 2 \times 10^{-16}$
Age.C	-0.2406	0.0595	-4.044	5.26×10^{-5}
Age^4	-0.0261	0.0568	-0.459	0.6459
Age^5	-0.1352	0.0538	-2.515	0.0119
Age^6	0.0381	0.0500	0.763	0.4452
Age^7	0.1010	0.0465	2.171	0.0300
Age^8	-0.0761	0.0427	-1.784	0.0744
Age^9	0.0820	0.0378	2.166	0.0303
Age^{10}	-0.1037	0.0329	-3.149	0.0016
Age^{11}	0.0890	0.0290	3.070	0.0021
Age^{12}	0.0220	0.0249	0.884	0.3767
HighChol1	0.5655	0.0144	39.259	$< 2 \times 10^{-16}$
DiffWalk1	0.1160	0.0181	6.414	1.42×10^{-10}
Income.L	-0.3315	0.0252	-13.159	$< 2 \times 10^{-16}$
Income.Q	-0.0799	0.0222	-3.592	0.0003
Income.C	-0.0173	0.0214	-0.809	0.4187
Income^4	-0.0265	0.0213	-1.242	0.2142
Income^5	0.0004	0.0210	0.019	0.9850
Income^6	-0.0236	0.0205	-1.155	0.2480
Income^7	0.0136	0.0201	0.678	0.4981
PhysHlth	-0.0033	0.0009	-3.927	8.62×10^{-5}
HeartDiseaseorAttack1	0.2965	0.0189	15.654	$< 2 \times 10^{-16}$
Education.L	-0.1150	0.1312	-0.877	0.3807
Education.Q	-0.1168	0.1193	-0.979	0.3277
Education.C	0.1427	0.0846	1.688	0.0914
Education^4	-0.1394	0.0493	-2.825	0.0047
Education^5	0.0069	0.0277	0.248	0.8040
PhysActivity1	-0.0322	0.0153	-2.111	0.0348

Nhận xét: Kết quả hồi quy logistic cho thấy nhiều biến có ảnh hưởng có ý nghĩa thống kê đến xác suất mắc bệnh (với p-value $< 0{,}05$). Các yếu tố như tình trạng sức khỏe tổng quát (*GenHlth*), tuổi (*Age*), chỉ số khối cơ thể (*BMI*), huyết áp cao (*HighBP*), cholesterol cao (*HighChol*) và tiền sử bệnh tim mạch (*HeartDiseaseorAttack*) có hệ số hồi quy dương, cho thấy các yếu tố này làm gia tăng nguy cơ mắc bệnh. Ngược lại, thu nhập (*Income*) và mức độ hoạt động thể chất (*PhysActivity*) có xu hướng làm giảm xác suất mắc bệnh. Nhìn chung, mô hình phản ánh hợp lý mối liên hệ giữa các yếu tố nhân khẩu học, lối sống và tình trạng sức khỏe với nguy cơ bệnh, đồng thời các biến quan trọng đều đạt ý nghĩa thống kê cao.

Về ý nghĩa của mỗi ước lượng, ta sẽ tính tỷ lệ cược - odds cho mỗi biến trong bảng 22.

Bảng 22: Tỷ lệ cược (Odds Ratio) của các biến trong mô hình hồi quy logistic 2

Biến	**OR**
(Intercept)	0.0125
GenHlth.L	4.7674
GenHlth.Q	0.7085
GenHlth.C	0.9207
GenHlth^4	1.0232
HighBP1	2.0144
BMI	1.0616
Age.L	9.6384
Age.Q	0.4986
Age.C	0.7862
Age^4	0.9742
Age^5	0.8735
Age^6	1.0389
Age^7	1.1063
Age^8	0.9267
Age^9	1.0854
Age^{10}	0.9015
Age^{11}	1.0931
Age^{12}	1.0223

Biến	**OR**
HighChol1	1.7603
DiffWalk1	1.1230
Income.L	0.7178
Income.Q	0.9233
Income.C	0.9829
Income^4	0.9739
Income^5	1.0004
Income^6	0.9766
Income^7	1.0137
PhysHlth	0.9967
HeartDiseaseorAttack1	1.3452
Education.L	0.8914
Education.Q	0.8898
Education.C	1.1534
Education^4	0.8699
Education^5	1.0069
PhysActivity1	0.9683

Nhận xét:

Đối với các biến có tỷ lệ cược lớn hơn 1 (Odds Ratio > 1):

- **GenHlth.L (OR = 4.77):** đây là một trong những yếu tố dự báo quan trọng nhất trong mô hình. Các thành phần bậc cao hơn của biến này (GenHlth.Q, GenHlth.C, GenHlth^4) có Odds Ratio dao động quanh 1, phản ánh mối quan hệ phi tuyến giữa sức khỏe tổng quát và nguy cơ mắc bệnh.
- **HighBP (OR = 2.01):** những cá nhân bị cao huyết áp có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 101% so với nhóm không bị cao huyết áp.
- **BMI (OR = 1.06):** khi chỉ số BMI tăng thêm một đơn vị, nguy cơ mắc bệnh tiểu đường tăng khoảng 6%, cho thấy vai trò đáng kể của tình trạng thừa cân và béo phì trong sự phát triển của bệnh.
- **Age.L (OR = 9.64):** tuổi là yếu tố có ảnh hưởng rất mạnh đến nguy cơ mắc bệnh tiểu đường. Odds Ratio lớn cho thấy nguy cơ mắc bệnh tăng nhanh theo tuổi.
- **HighChol (OR = 1.76):** nhóm có cholesterol cao có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 76% so với nhóm không có cholesterol cao, cho thấy vai trò của rối loạn lipid máu trong bệnh lý tiểu đường.
- **DiffWalk (OR = 1.12):** những người gặp khó khăn khi đi lại có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 12%, phản ánh mối liên hệ giữa suy giảm chức năng vận động và tình trạng sức khỏe kém.
- **HeartDiseaseorAttack (OR = 1.35):** những cá nhân có tiền sử bệnh tim mạch có nguy cơ mắc bệnh tiểu đường cao hơn khoảng 35%.

Đối với các biến có tỷ lệ cược nhỏ hơn 1 (Odds Ratio < 1):

- **PhysActivity (OR = 0.96):** Những người có tham gia hoạt động thể chất có nguy cơ mắc bệnh tiểu đường thấp hơn khoảng 4% so với những người không hoạt động thể chất, cho thấy vai trò bảo vệ nhẹ của vận động đối với sức khỏe chuyển hóa.

- **HvyAlcoholConsump (OR = 0.51):** Nhóm tiêu thụ rượu ở mức cao có Odds Ratio nhỏ hơn 1. Tuy nhiên, kết quả này cần được cân nhắc kỹ do khả năng tồn tại các yếu tố gây nhiễu hoặc sai lệch trong khai báo hành vi uống rượu.

- **Fruits và Veggies (OR xấp xỉ 1):** Việc tiêu thụ trái cây và rau xanh cho thấy xu hướng làm giảm nhẹ nguy cơ mắc bệnh tiểu đường, tuy nhiên mức độ ảnh hưởng không mạnh khi đã kiểm soát các yếu tố khác trong mô hình.

- **Income (OR = 0.68):** Thu nhập có Odds Ratio nhỏ hơn 1, cho thấy thu nhập cao hơn có xu hướng làm giảm nguy cơ mắc bệnh tiểu đường. Các thành phần bậc cao hơn có OR gần 1, phản ánh mối quan hệ phi tuyến giữa thu nhập và nguy cơ bệnh.

- **Education:** Các thành phần của biến Education có Odds Ratio dao động quanh 1, cho thấy trình độ học vấn không có ảnh hưởng mạnh và nhất quán đến nguy cơ mắc bệnh tiểu đường khi đã kiểm soát các yếu tố sức khỏe và nhân khẩu học khác.

Nhìn chung, các yếu tố phản ánh trực tiếp tình trạng sức khỏe cá nhân như cao huyết áp, cholesterol cao, tiền sử bệnh tim mạch, chỉ số BMI và đặc biệt là tuổi có ảnh hưởng rõ rệt đến nguy cơ mắc bệnh tiểu đường. Trong khi đó, các yếu tố kinh tế – xã hội và lối sống như thu nhập, trình độ học vấn và hoạt động thể chất chỉ cho thấy tác động yếu hoặc không nhất quán khi đã kiểm soát các yếu tố khác trong mô hình. Kết quả cũng chỉ ra mối quan hệ phi tuyến đáng kể giữa tuổi, sức khỏe tổng quát và nguy cơ mắc bệnh tiểu đường, được thể hiện qua các thành phần đa thức bậc cao có hệ số khác nhau quanh giá trị 1.

6.2.6 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu gốc

Dự đoán mô hình với ngưỡng phân loại 0.3 trên tập test cho thấy độ chính xác giảm mạnh xuống còn 81.87% cho thấy độ chính xác của mô hình khá tốt. Kết quả ma trận nhầm lẫn được trình bày trong bảng 23.

Bảng 23: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**
0	37627	4037
1	5161	3911

Nhận xét: Kết quả cho thấy mô hình đã giảm thiên lệch về lớp đa số và phù hợp hơn với mục tiêu sàng lọc tiểu đường.

6.2.7 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu cân bằng

Nhằm hạn chế ảnh hưởng của sự mất cân bằng lớp trong dữ liệu, mô hình được ước lượng lại trên tập dữ liệu đã cân bằng để đánh giá chính xác hơn hiệu quả dự đoán. Số lượng quán sát trong mỗi nhóm bệnh sau khi cân bằng dữ liệu như sau:

Bảng 24: Số lượng quan sát trong mỗi nhóm bệnh sau khi cân bằng dữ liệu

Nhóm	**0**	**1**
Số lượng	170915	170915

Ta có kết quả ước lượng trong bảng 25.

Bảng 25: Kết quả ước lượng mô hình hồi quy logistic trên tập dữ liệu cân bằng

Biến	**Estimate**	**Std. Error**	**z-value**	**Pr(>|z|)**
(Intercept)	-3.8620	0.04128	-93.552	$< 2 \times 10^{-16}$
GenHlth.L	1.9510	0.01969	99.086	$< 2 \times 10^{-16}$
GenHlth.Q	-0.5290	0.01451	-36.454	$< 2 \times 10^{-16}$
GenHlth.C	0.0213	0.01093	1.952	0.05093
GenHlth^4	-0.0073	0.00817	-0.892	0.37217
HighBP1	0.7119	0.00908	78.398	$< 2 \times 10^{-16}$
BMI	0.0785	0.00077	102.365	$< 2 \times 10^{-16}$
Age.L	3.4260	0.04332	79.079	$< 2 \times 10^{-16}$
Age.Q	-0.9067	0.04119	-22.010	$< 2 \times 10^{-16}$
Age.C	-0.3910	0.03847	-10.163	$< 2 \times 10^{-16}$
Age^4	0.0696	0.03678	1.893	0.05836
Age^5	-0.1450	0.03480	-4.167	3.09×10^{-5}
Age^6	0.0797	0.03225	2.471	0.01348
Age^7	0.0939	0.02996	3.136	0.00171
Age^8	-0.0771	0.02730	-2.823	0.00476
Age^9	0.1192	0.02392	4.985	6.19×10^{-7}
Age^{10}	-0.1633	0.02042	-7.993	1.32×10^{-15}
Age^{11}	0.1061	0.01771	5.988	2.12×10^{-9}
Age^{12}	0.0649	0.01497	4.337	1.44×10^{-5}
HighChol1	0.5541	0.00866	63.967	$< 2 \times 10^{-16}$
DiffWalk1	0.0377	0.01224	3.081	0.00206
Income.L	-0.1379	0.01701	-8.106	5.24×10^{-16}
Income.Q	-0.0154	0.01481	-1.040	0.29827
Income.C	0.0001	0.01414	0.006	0.99500
Income^4	-0.0104	0.01408	-0.735	0.46248
Income^5	0.0145	0.01378	1.049	0.29410
Income^6	-0.0124	0.01336	-0.925	0.35497
Income^7	0.0373	0.01306	2.859	0.00425
PhysHlth	-0.0071	0.00059	-11.971	$< 2 \times 10^{-16}$
HeartDiseaseorAttack1	0.1139	0.01308	8.714	$< 2 \times 10^{-16}$
Education.L	0.6781	0.1123	6.039	1.55×10^{-9}
Education.Q	-0.5196	0.1022	-5.084	3.70×10^{-7}
Education.C	0.1751	0.07181	2.438	0.01476
Education^4	-0.1756	0.04056	-4.329	1.50×10^{-5}
Education^5	0.1274	0.02080	6.126	9.02×10^{-10}
PhysActivity1	0.0525	0.00977	5.369	7.91×10^{-8}

Nhận xét: Ta thấy rằng phần lớn các biến giải thích đều có ý nghĩa thống kê cao, thể hiện qua giá trị p-value rất nhỏ, do đó, các biến dùng để hồi quy cho Diabetes_binary đều có đóng góp đáng kể trong việc phân loại đối tượng mắc và không mắc bệnh tiểu đường ở mức ý nghĩa $\alpha = 5\%$. Tuy nhiên, mô hình vẫn tồn tại một số thành phần không đạt ý nghĩa thống kê, chủ yếu thuộc các bậc cao của biến *GenHlth* ($GenHlth^4$), một số bậc cao của *Income* ($Income.Q$, $Income.C$, $Income^4$–$Income^6$), và một vài bậc của *Age* có mức ý nghĩa biên (như Age^4 với $p \approx 0.058$). Việc giữ lại các thành phần này cần được cân nhắc thêm nhằm tối ưu hóa độ phức tạp của mô hình.

Về ý nghĩa của mỗi ước lượng, ta sẽ tính tỷ lệ cược - odds cho mỗi biến trong bảng 26.

Bảng 26: Tỷ lệ cược (Odds Ratio) của các biến trong mô hình hồi quy logistic

Biến	**OR**
(Intercept)	0.0210
GenHlth.L	7.0335
GenHlth.Q	0.5892
GenHlth.C	1.0216
$GenHlth^4$	0.9927
HighBP1	2.0379
BMI	1.0817
Age.L	30.7498
Age.Q	0.4039
Age.C	0.6764
Age^4	1.0721
Age^5	0.8650
Age^6	1.0829
Age^7	1.0985
Age^8	0.9258

Biến	**OR**
Age^9	1.1267
Age^{10}	0.8494
Age^{11}	1.1119
Age^{12}	1.0671
HighChol1	1.7403
DiffWalk1	1.0384
Income.L	0.8712
Income.Q	0.9847
Income.C	1.0001
$Income^4$	0.9897
$Income^5$	1.0146
$Income^6$	0.9877
$Income^7$	1.0380
PhysHlth	0.9930
HeartDiseaseorAttack1	1.1207
Education.L	1.9702
Education.Q	0.5947
Education.C	1.1913
$Education^4$	0.8390
$Education^5$	1.1359
PhysActivity1	1.0539

Nhận xét:

- Biến *Age.L* có OR rất lớn (30.75), phản ánh mối quan hệ tăng mạnh và phi tuyến giữa tuổi tác và xác suất mắc bệnh. Tương tự, biến *GenHlth.L* cũng có OR cao (7.03), khẳng định vai trò quan trọng của tình trạng sức khỏe.
- Các biến *HighBP1* (OR = 2.04), *HighChol1* (OR = 1.74) và *HeartDiseaseorAttack1* (OR = 1.12) đều có OR lớn hơn 1, cho thấy sự gia tăng đáng kể nguy cơ mắc tiểu đường ở nhóm đối tượng có các bệnh lý tim mạch liên quan.
- Chỉ số *BMI* có OR = 1.08, cho thấy mỗi đơn vị tăng của BMI làm tăng nhẹ nhưng có ý nghĩa nguy cơ mắc tiểu đường. Biến *DiffWalk1* cũng có OR lớn hơn 1 (OR = 1.04), phản ánh mối liên hệ giữa hạn chế vận động và nguy cơ bệnh.
- Ngược lại, các biến *Income* và *Education* thể hiện ảnh hưởng không tuyến tính và tương đối yếu.
- Các biến *PhysActivity1* (OR = 1.05) và *PhysHlth* (OR = 0.99) có OR gần 1, cho thấy ảnh hưởng hạn chế đến xác suất mắc bệnh tiểu đường.

Nhìn chung, kết quả cho thấy nguy cơ mắc bệnh tiểu đường vẫn chịu ảnh hưởng chủ yếu bởi các yếu tố sức khỏe và bệnh lý nền, trong khi các yếu tố lối sống và kinh tế – xã hội đóng vai trò thứ yếu trong mô hình.

6.2.8 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu cân bằng

Dự đoán mô hình với ngưỡng phân loại 0.6 trên tập test cho thấy độ chính xác đạt 77.49%. Đây là một tỷ lệ dự đoán khá ổn, kết quả ma trận nhầm lẫn của mô hình dự đoán được trình bày trong bảng 27.

Bảng 27: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**
0	34197	2831
1	8591	5117

Nhận xét: Kết quả cho thấy mô hình đã cải thiện rõ rệt khả năng phát hiện nhóm mắc bệnh, song số trường hợp mắc bệnh giả ở nhóm không mắc bệnh lại gia tăng một cách đáng kể.

6.3 Mô hình hồi quy multinomial logistic

Mô hình hồi quy multinomial logistic với k nhóm:

$$\log\left(\frac{\pi(\boldsymbol{x}_j)}{\pi(\boldsymbol{x}_1)}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p, \quad j = 2, \ldots, k. \tag{2}$$

Nhóm $j = 1$ được chọn làm lớp tham chiếu, tức là mô hình sẽ ước tính các tham số cho các lớp $j = 2, 3, \ldots, k$ so với lớp tham chiếu $j = 1$. Trong phần này ta chọn nhóm không bị tiểu đường (0) để làm nhóm tham chiếu.

6.3.1 Ước lượng mô hình trên tập dữ liệu gốc

Ta có kết quả ước lượng trong bảng sau:

Bảng 28: Hệ số hồi quy của mô hình multinomial logistic

Nhóm 1		**Nhóm 2**	
Variable	**Coefficient (β)**	**Variable**	**Coefficient (β)**
(Intercept)	-6.5381	(Intercept)	-5.9055
HighBP	0.3543	HighBP	0.7309
HighChol	0.5698	HighChol	0.5554
CholCheck	0.7866	CholCheck	1.2163
BMI	0.0478	BMI	0.0606
Smoker	-0.0160	Smoker	-0.0393
Stroke	-0.1017	Stroke	0.1705
HeartDiseaseorAttack	0.0044	HeartDiseaseorAttack	0.2586
PhysActivity	-0.0150	PhysActivity	-0.0476
Fruits	-0.0258	Fruits	-0.0183
Veggies	-0.0434	Veggies	-0.0379
HvyAlcoholConsump	-0.1860	HvyAlcoholConsump	-0.7606
AnyHealthcare	-0.0624	AnyHealthcare	0.0905
NoDocbcCost	0.3585	NoDocbcCost	0.0265
GenHlth (L)	0.7891	GenHlth (L)	1.6538
GenHlth (Q)	-0.3512	GenHlth (Q)	-0.3715
GenHlth (C)	-0.0902	GenHlth (C)	-0.0796
GenHlth (4)	-0.0552	GenHlth (4)	0.0330
MentHlth	0.0077	MentHlth	-0.0027
PhysHlth	-0.0012	PhysHlth	-0.0034
DiffWalk	-0.0310	DiffWalk	0.1482
Sex	0.0939	Sex	0.2705
Age (L)	1.8910	Age (L)	2.3481
Age (Q)	-0.4105	Age (Q)	-0.7913
Age (C)	0.0649	Age (C)	-0.2586

Để hiểu rõ hơn về ý nghĩa của các hệ số, ta tính exp() của các ước lượng hệ số, cũng chính là tỷ số rủi ro tương đối - relative risk ratio (RRR) của

từng biến:

```
  (Intercept)  HighBP1 HighChol1 CholCheck1      BMI   Smoker1   Stroke1
1 0.001447215 1.425140  1.767895   2.195872 1.048919 0.9840797 0.9032906
2 0.002724371 2.076856  1.742613   3.374765 1.062439 0.9614391 1.1859354
  HeartDiseaseorAttack1 PhysActivity1   Fruits1  Veggies1 HvyAlcoholConsump1
1              1.004411     0.9850937 0.9745030 0.9575089          0.8302491
2              1.295100     0.9535506 0.9818765 0.9627919          0.4673746
  AnyHealthcare1 NoDocbcCost1 GenHlth.L GenHlth.Q GenHlth.C GenHlth^4 MentHlth  PhysHlth
1      0.9395105     1.431160  2.201484 0.7038457 0.9137325 0.9463308 1.007746 0.9988415
2      1.0947352     1.026902  5.226756 0.6896725 0.9234406 1.0335651 0.997347 0.9966035
  DiffWalk1     Sex1     Age.L     Age.Q     Age.C     Age^4     Age^5     Age^6    Age^7
1 0.9694823 1.098482  6.626311 0.6633162 1.0670127 0.8652538 1.0335884 0.8653634 1.148720
2 1.1597231 1.310572 10.466083 0.4532521 0.7721031 0.9976233 0.8382691 1.0869756 1.067848
      Age^8    Age^9    Age^10   Age^11    Age^12 Education.L Education.Q Education.C
1 0.8575514 1.175801 0.8580356 1.301480 0.9139232    1.244722   0.5725836    1.663409
2 0.9539777 1.063119 0.9184979 1.056855 1.0427402    0.880912   0.9343362    1.082005
  Education^4 Education^5  Income.L  Income.Q  Income.C  Income^4  Income^5  Income^6
1   0.7259469   0.9859409 0.6334920 0.9656667 0.8594975 0.9347983 0.9981148 1.0121490
2   0.8892139   1.0068651 0.6882513 0.9056977 1.0018167 0.9787979 0.9972651 0.9731898
   Income^7
1 0.9852394
2 1.0176301
```

Hình 11: Tỷ số rủi ro tương đối - relative risk ratio (RRR)

Nhận xét:

- **HighBP:**
  - Nhóm tiền tiểu đường có nguy cơ cao hơn 1.4351 lần (43.51%) so với nhóm không bị tiểu đường.
  - Nhóm tiểu đường có nguy cơ cao hơn 2.0769 lần (107.69%) so với nhóm không bị tiểu đường.
- **HighChol:** Cả hai nhóm đều có nguy cơ tương đối cao (trên 1.7 lần (70%)), cho thấy cholesterol cao là một yếu tố nguy cơ đáng kể đối với cả tiền tiểu đường và tiểu đường.
- **CholCheck:**
  - Nhóm tiền tiểu đường có nguy cơ cao hơn 2.1959 lần (119.59%) khi kiểm tra cholesterol, cho thấy việc kiểm tra có thể liên quan đến tăng nguy cơ tiền tiểu đường.
  - Nhóm tiểu đường có nguy cơ cao hơn 3.3748 lần (237.48%) khi kiểm tra cholesterol, cho thấy việc kiểm tra có mối quan hệ mạnh với tăng nguy cơ tiểu đường.

- **BMI**: Mỗi đơn vị tăng của `BMI` làm tăng nguy cơ vào nhóm tiền tiểu đường lên 1.0489 lần (4.89%) và vào nhóm tiểu đường lên 1.0624 lần (6.24%), cho thấy ảnh hưởng tăng dần từ thừa cân/béo phì.

- **Stroke**: Tác động của việc từng bị đột quỵ có xu hướng giảm nhẹ nguy cơ vào nhóm 1 (0.9033) nhưng tăng nguy cơ vào nhóm 2 (1.1859). Mặc dù tác động tăng giảm không cao nhưng nó cho thấy xu hướng bị đột quỵ sẽ tăng nguy cơ tiểu đường, bỏ qua tiền tiểu đường.

- **HvyAlcoholConsump**: Là yếu tố giảm nguy cơ rõ rệt ở cả hai nhóm, với 0.8302 ở nhóm 1 và 0.4674 ở nhóm 2, đặc biệt liên quan mạnh hơn đến bệnh tiểu đường. Mặc dù các nghiên cứu cho thấy rằng uống một lượng rượu vừa phải có thể làm giảm nguy cơ mắc bệnh tiểu đường, trong trường hợp này cũng chỉ đánh giá theo thang từ 0 đến 1, nên chưa thể hiện được mức độ sử dụng rượu cao, ở đây ta chỉ ghi nhận ở mức 0 đến mức 1, không sử dụng rượu đến sử dụng rượu nhưng trong mức độ cho phép.

- **GenHlth**:
  - Tình trạng sức khỏe càng kém nguy cơ thuộc nhóm 1 và nhóm 2 càng cao.
  - **GenHlth.L**: Tăng nguy cơ thuộc nhóm 1 lên 2.2015 lần (120.15%) và nhóm 2 lên 5.2268 lần (422.68%).
  - Mức độ ảnh hưởng mạnh hơn ở nhóm 2, cho thấy sức khỏe tổng quát kém có liên hệ mật thiết với nguy cơ bệnh tiểu đường.

- **MentHlth**: làm tăng nguy cơ tiền tiểu đường và tiểu đường, con số ảnh hưởng cũng rất rất nhỏ, trên hai nhóm đều dưới 1%.

- **Age**:
  - Nguy cơ tăng dần theo tuổi ở cả hai nhóm.
  - **Age.L**: Tăng nguy cơ thuộc nhóm 1 lên tới 6.6263 lần (562.63%) và nhóm 2 lên 10.4661 lần (946.61%).

- **Income**: Thu nhập cao hơn liên quan đến nguy cơ mắc bệnh thấp hơn ở cả hai nhóm.

Kết luận:

- Các yếu tố như huyết áp cao, cholesterol cao, kiểm tra cholesterol, BMI, sức khỏe tổng quát kém, và tuổi cao đóng vai trò quan trọng trong nguy cơ mắc tiền tiểu đường và tiểu đường.
- Các yếu tố bảo vệ bao gồm thu nhập cao và tiêu thụ rượu có hạn mức vừa phải cũng được thể hiện rõ trong mối quan hệ với RRR thấp hơn.
- Tác động của từng yếu tố mạnh hơn khi chuyển từ nhóm 1 (tiền tiểu đường) sang nhóm 2 (tiểu đường), cho thấy nguy cơ tích lũy khi bệnh tiến triển.

6.3.2 Tiên đoán mô hình trên tập dữ liệu gốc

Dự đoán mô hình trên tập test: Kết quả thu được cho dự báo mô hình trên tập test là 84.92% tỉ lệ phân loại đúng ba nhóm của dữ liệu. Tỉ lệ dự đoán khá tốt tuy nhiên vẫn còn nhiều bất cập do số lượng nhóm 0 quá lớn, mô hình có xu hướng thiên lệch mạnh về nhóm 0, dự đoán rất kém cho các lớp thiểu số (đặc biệt lớp 1 gần như không được nhận diện), phản ánh ảnh hưởng rõ rệt của mất cân bằng lớp đến hiệu quả phân loại. Vì vậy, độ tin cậy lúc này vẫn chưa cao, ta có thể xem ma trận nhầm lẫn của mô hình dự đoán ở bảng 29.

Bảng 29: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**	**2**
0	41817	806	5799
1	0	0	0
2	971	74	1269

Nhận xét: Hầu hết các quan sát được dự đoán vào nhóm 0, mô hình không dự đoán được bất kỳ mẫu nào thuộc nhóm 1, và chỉ nhận diện được một phần nhỏ nhóm 2, dẫn đến khả năng phân biệt các nhóm bệnh tiểu đường không đồng đều và hiệu quả dự đoán kém đối với các nhóm thiểu số. Do đó, ta sẽ áp dụng phương pháp Cân bằng dữ liệu để giải quyết vấn đề chênh lệch số lượng các nhóm và ước lượng lại mô hình.

6.3.3 Ước lượng mô hình trên tập dữ liệu cân bằng

Từ việc cân bằng dữ liệu, các biến phân loại không còn chia nhóm theo quy tắc hữu hạn theo số đếm nên ta sẽ để dạng biến liên tục để thực hiện hồi quy, ta sẽ xem bảng tỷ số rủi ro tương đối - relative risk ratio với dữ liệu cân bằng thì các tác động 'lạ' của các biến **stroke** và **Menthlth** có hiệu quả khác hay không. Ta có kết quả tỷ số rủi ro tương đối - relative risk ratio với dữ liệu cân bằng.

```
   (Intercept)   HighBP1 HighChol1 CholCheck1      BMI  Smoker1    Stroke1
1 1.914164e-12 0.3970284  1.783007  17.300545 1.074092 2.421254 0.03819522
2 6.689505e-12 0.5784037  1.713697   9.464627 1.105858 2.229034 0.12581287
  HeartDiseaseorAttack1 PhysActivity1  Fruits1  Veggies1 HvyAlcoholConsump1 AnyHealthcare1
1             0.9355308     0.4588943 3.399944 0.3652915           1.173865       1.377426
2             1.4672822     0.4416649 3.358336 0.3575844           1.575591       1.416105
  NoDocbcCost1 GenHlth.L GenHlth.Q GenHlth.C GenHlth^4  MentHlth PhysHlth DiffWalk1
1     9.715838 0.2994886 0.5270673  1.141996  1.382615 0.9297415 1.009847 0.2533316
2     7.067193 0.7143475 0.5009311  1.132260  1.463388 0.9148998 1.009007 0.2995798
      Sex1    Age.L      Age.Q    Age.C     Age^4    Age^5    Age^6      Age^7    Age^8
1 1.320470 447.4258 0.07109714 171.0865 0.6397447 46.32782 44.29941 0.05368870 67.30978
2 1.678484 410.6727 0.06010099 149.3109 0.4917581 45.08284 41.58344 0.06027129 68.94459
      Age^9    Age^10    Age^11   Age^12 Education.L Education.Q Education.C Education^4
1 1.0662267 0.4903806 1.2836477 2.081078 0.009554197    20.33832   1.1247509  0.01773785
2 0.9128744 0.6369420 0.8253203 2.846272 0.001483360    98.91451   0.4475243  0.02543768
  Education^5  Income.L Income.Q Income.C Income^4 Income^5  Income^6  Income^7
1    38.01981 0.1350315 1.793383 1.643381 2.308891 3.745580 0.4913363 0.6332046
2    35.18609 0.1339462 1.462261 1.914727 2.465853 3.666209 0.4840240 0.6533265
  Diabetes_binary1
1     2.686292e+18
2     6.498131e+17
```

Hình 12: Tỷ số rủi ro tương đối - relative risk ratio (RRR)

Nhận xét: Ta thấy rằng kết quả thu được khá giống với nhận xét mô hình ở dữ liệu gốc, các tỷ số có sự chênh lệch nhẹ nhưng không thay đổi vai trò của nó.

6.3.4 Tiên đoán mô hình trên tập dữ liệu cân bằng

Dự đoán mô hình trên tập test: Kết quả thu được cho dự báo mô hình trên tập test là 93.49% tỉ lệ phân loại đúng ba nhóm của dữ liệu. Ta có thể xem ma trận nhầm lẫn của mô hình dự đoán ở bảng 30.

Bảng 30: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**	**2**
0	42788	0	0
1	0	472	2897
2	0	408	4171

Nhận xét: Khả năng nhận diện nhóm 1 và nhóm 2 đã được cải thiện đáng kể so với dữ liệu mất cân bằng. Mặc dù mô hình có thể phát hiện được khá nhiều ca bệnh, nhưng rất nhiều dự đoán dương là sai. Nhìn chung, việc cân bằng dữ liệu giúp mô hình giảm thiên lệch về nhóm 0, giúp tăng khả năng phân biệt các nhóm tiểu đường thiểu số.

6.3.5 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu gốc

Dựa trên kết quả chọn biến ở phần trên, nhóm tiến hành xây dựng mô hình hồi quy multinomial logistic với Diabetes_012 là biến phụ thuộc và 11 biến giải thích gồm GenHlth, HighBP, BMI, Age, HighChol, DiffWalk, Income, PhysHlth, HeartDiseaseorAttack, Education và PhysActivity. Ta có kết quả tỷ số rủi ro tương đối - relative risk ratio của trường hợp 11 biến trong bảng 31.

Bảng 31: Tỷ số rủi ro tương đối - relative risk ratio (RRR)

Biến	**Nhóm 1 (RRR)**	**Nhóm 2 (RRR)**
Intercept	0.0031	0.0095
GenHlth.L	2.3368	5.3489
GenHlth.Q	0.7136	0.6925
GenHlth.C	0.9153	0.9236
GenHlth^4	0.9451	1.0343
HighBP	1.4455	2.1253
BMI	1.0496	1.0633
Age.L	5.7024	10.9595
Age.Q	0.6387	0.4690
Age.C	1.0713	0.7494
Age^4	0.8782	1.0139
Age^5	1.0350	0.8276
Age^6	0.8582	1.0950
Age^7	1.1486	1.0765
Age^8	0.8557	0.9528
Age^9	1.1741	1.0605
Age^{10}	0.8613	0.9182
Age^{11}	1.3036	1.0572
Age^{12}	0.9171	1.0441
HighChol	1.8010	1.7561
DiffWalk	0.9777	1.1412
Income.L	0.6011	0.7357
Income.Q	0.9583	0.9197
Income.C	0.8605	1.0022
PhysHlth	1.0009	0.9961
HeartDiseaseorAttack	1.0186	1.3860
Education.L	1.1866	0.8708
Education.Q	0.5890	0.9278
Education.C	1.6536	1.1090
PhysActivity	0.9822	0.9668

Nhận xét: Kết quả cho thấy tất cả các biến đều thể hiện đúng vai trò như trong nhận xét của mô hình ban đầu.

6.3.6 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu gốc

Dự đoán mô hình trên tập test: Kết quả thu được cho dự báo mô hình trên tập test là 84.79% tỉ lệ phân loại đúng ba nhóm của dữ liệu. Ta có thể xem ma trận nhầm lẫn của mô hình dự đoán ở bảng 32.

Bảng 32: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**	**2**
0	41834	797	5881
1	0	0	0
2	954	83	1187

Nhận xét: Kết quả vẫn cho thấy hầu hết các quan sát được dự đoán vào nhóm 0, mô hình không dự đoán được bất kỳ mẫu nào thuộc nhóm 1, và chỉ nhận diện được một phần nhỏ nhóm 2. Do đó, ta sẽ áp dụng phương pháp Cân bằng dữ liệu để giải quyết vấn đề chênh lệch số lượng các nhóm và ước lượng lại mô hình.

6.3.7 Ước lượng mô hình với 11 biến giải thích trên tập dữ liệu cân bằng

Ta có kết quả tỷ số rủi ro tương đối - relative risk ratio với dữ liệu cân bằng.

```
  (Intercept) GenHlth.L GenHlth.Q GenHlth.C GenHlth^4  HighBP1      BMI    Age.L     Age.Q
1  0.02174434  3.844768 0.6030416  1.040006 0.9655674 1.365721 1.070956 45.07121 0.3817650
2  0.01168213  8.583738 0.5783643  1.020553 1.0291494 2.047522 1.096129 52.71268 0.3164301
      Age.C    Age^4     Age^5    Age^6    Age^7     Age^8    Age^9    Age^10   Age^11
1 0.7819277 1.319731 0.8734926 1.178604 1.087286 0.8707714 1.389572 0.6489622 1.560296
2 0.6570633 1.063275 0.8185721 1.144716 1.219880 0.8891508 1.192640 0.8303520 1.027583
     Age^12 HighChol1 DiffWalk1  Income.L  Income.Q  Income.C  Income^4 Income^5 Income^6
1 0.8919512  1.785283 0.7965652 0.7811065 1.1246079 0.8201329 0.9342882 1.060127 1.027058
2 1.1837452  1.703793 0.9498002 0.8995240 0.9226872 0.9905977 0.9757860 1.035529 1.010889
   Income^7  PhysHlth HeartDiseaseorAttack1 Education.L Education.Q Education.C
1 0.9635049 0.9985809             0.6385844   17.002519  0.09691454    3.487622
2 0.9954369 0.9932804             1.1476664    2.494396  0.48981048    1.369095
  Education^4 Education^5 PhysActivity1
1   0.4976601    1.301965      1.107571
2   0.7427762    1.187938      1.059617
```

Hình 13: Tỷ số rủi ro tương đối - relative risk ratio (RRR)

Nhận xét: Như các nhận xét trước, các yếu tố sức khỏe như huyết áp, cholesterol, bệnh về tim mạch, và tuổi tác và sức khỏe tổng quát có ảnh hưởng lớn hơn nhiều đến nguy cơ mắc bệnh tiểu đường so với các yếu tố lối sống và kinh tế.

6.3.8 Tiên đoán mô hình với 11 biến giải thích trên tập dữ liệu cân bằng

Dự đoán mô hình trên tập test: Kết quả thu được cho dự báo mô hình trên tập test là 61.81% tỉ lệ phân loại đúng ba nhóm của dữ liệu. Ta có thể xem ma trận nhầm lẫn của mô hình dự đoán ở bảng 33.

Bảng 33: Ma trận nhầm lẫn của mô hình dự đoán

Tiên đoán \ Thực tế	**0**	**1**	**2**
0	27145	241	1170
1	8936	273	1955
2	6707	366	3943

Nhận xét:

Với dữ liệu đã được cân bằng, ma trận nhầm lẫn cho thấy mô hình không còn thiên lệch nghiêm trọng về một lớp duy nhất như trước và đã dự đoán được cả ba nhóm. Tuy nhiên, vẫn còn sự nhầm lẫn đáng kể giữa các nhóm, đặc biệt là giữa Nhóm 0 và Nhóm 1/2, thể hiện qua số lượng lớn các quan sát của lớp 0 bị dự đoán sang lớp 1 và 2, cho thấy mô hình còn hạn chế trong việc phân biệt ranh giới giữa các mức độ bệnh tiểu đường. Điều đó cho thấy cần tiếp tục cân nhắc các hướng cải tiến như thử nghiệm các mô hình phi tuyến để đạt hiệu quả phân loại tốt hơn.

Kết luận: Đối với mô hình hồi quy multinomial logistic, khi huấn luyện trên dữ liệu gốc chưa cân bằng, mô hình có xu hướng dự đoán hầu hết các quan sát vào Nhóm 0 do sự chênh lệch lớn về phân bố dữ liệu giữa các nhóm. Điều này làm cho độ tin cậy của mô hình thấp, mặc dù độ chính xác tổng thể có thể cao.

Khi mô hình được xây dựng trên dữ liệu đã cân bằng, mô hình phản ánh tốt hơn khả năng phân biệt giữa các nhóm. Kết quả cho thấy mô hình vẫn

dự đoán khá ổn đối với Nhóm 0 và Nhóm 2, trong khi xác suất dự đoán sai giữa hai nhóm này là tương đối thấp. Phần lớn các sai lệch trong dự đoán xuất phát từ việc nhầm lẫn với Nhóm 1, cho thấy nhóm này có đặc trưng chồng lấn với hai nhóm còn lại.

Sau khi loại bỏ các biến ít ý nghĩa thống kê hoặc gây nhiễu, mô hình multinomial logistic cuối cùng gồm 11 biến cho thấy khả năng dự đoán như sau: mô hình hoạt động tốt đối với Nhóm 0, với phần lớn các quan sát thực tế được phân loại chính xác; trong khi đó, khả năng dự đoán đối với Nhóm 1 và Nhóm 2 còn hạn chế. Điều này cho thấy mô hình vẫn gặp khó khăn trong việc phân biệt ranh giới giữa các mức độ bệnh tiểu đường trung gian và nặng.

Nhìn chung, mô hình hiện tại phù hợp nếu mục tiêu chính là nhận diện Nhóm 0, nhưng để nâng cao hiệu quả phân loại đối với Nhóm 1 và Nhóm 2, cần xem xét cải tiến thêm hoặc thử nghiệm các lý thuật khác nhằm nâng cao độ chính xác và tính ứng dụng trong thực tế.

7 Xây dựng mô hình GAM Logistic

7.1 Khái niệm chung

Mô hình GAM Logistic (Generalized Additive Model với phân phối nhị thức) là sự mở rộng của mô hình hồi quy Logistic cổ điển, cho phép mô tả mối quan hệ phi tuyến giữa biến mục tiêu và các biến giải thích thông qua các hàm trơn (smooth functions). Mô hình này đặc biệt phù hợp trong các bài toán y sinh và dịch tễ học, nơi mối quan hệ giữa các yếu tố nguy cơ và xác suất mắc bệnh thường không tuân theo dạng tuyến tính đơn giản.

Trong bài toán phân loại nhị phân, GAM Logistic được sử dụng để mô hình hóa xác suất xảy ra một sự kiện, ví dụ như xác suất một cá nhân có nguy cơ mắc bệnh tiểu đường.

Giả sử biến mục tiêu $Y \in \{0, 1\}$, với:

$$Y = \begin{cases} 1, & \text{nếu cá nhân có nguy cơ tiểu đường,} \\ 0, & \text{nếu cá nhân không tiểu đường.} \end{cases}$$

Xác suất có nguy cơ tiểu đường được ký hiệu là:

$$P(Y = 1 \mid \mathbf{X}) = p.$$

Trong mô hình GAM Logistic, hàm liên kết logit được biểu diễn dưới dạng:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + f_1(X_1) + f_2(X_2) + \cdots + f_k(X_k),$$

trong đó:

- β_0 là hằng số chặn (intercept),
- $X_1, X_2, \ldots, X_k$ là các biến giải thích,
- $f_j(\cdot)$ là các hàm trơn (smooth functions), thường được xấp xỉ bằng spline (ví dụ cubic spline hoặc thin plate spline).

Từ đó, xác suất có nguy cơ tiểu đường được suy ra:

$$p = \frac{\exp\left(\beta_0 + \sum_{j=1}^{k} f_j(X_j)\right)}{1 + \exp\left(\beta_0 + \sum_{j=1}^{k} f_j(X_j)\right)}.$$

7.2 So sánh với hồi quy Logistic cổ điển

Trong hồi quy Logistic truyền thống, mô hình có dạng:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k,$$

trong đó mối quan hệ giữa biến giải thích và log-odds được giả định là tuyến tính.

Giả định tuyến tính này có thể không phù hợp trong thực tế, đặc biệt đối với các biến liên tục như chỉ số khối cơ thể (BMI), tuổi hoặc các chỉ số sức khỏe, vốn thường có ảnh hưởng phi tuyến đến nguy cơ mắc bệnh. Mô hình GAM Logistic khắc phục hạn chế này bằng cách thay thế các thành phần tuyến tính $\beta_j X_j$ bằng các hàm trơn $f_j(X_j)$, cho phép mô hình linh hoạt hơn trong việc mô tả cấu trúc dữ liệu.

7.3 Mô hình GAM giữa 21 biến đóng góp so với biến Diabetes_binary.

Nhóm tiếp tục tiến hành mở rộng mô hình Logistic bằng cách mô hình hóa ảnh hưởng của biến liên tục dưới dạng hàm trơn, giúp bắt quan hệ phi tuyến.

Nhóm sử dụng biến *Diabetes_binary* đã được SMOTE nhằm tăng cường dữ liệu.

Bảng 34: Confusion matrix cho mô hình GAM giữa 21 biến đóng góp so với biến Diabetes_binary.

		Reference	
		0	**1**
Prediction	**0**	31115	2007
	1	11673	5941

Nhận xét:

- Mô hình dự đoán tốt đối với lớp 0, thể hiện qua số lượng True Negative (31115) rất lớn, cho thấy khả năng nhận diện đúng các quan sát thuộc lớp 0 là cao.
- Tuy nhiên, số lượng False Positive (11673) khá lớn, chứng tỏ mô hình có xu hướng dự đoán nhầm lớp 0 thành lớp 1, làm giảm độ đặc hiệu (specificity).
- Đối với lớp 1, mô hình phát hiện đúng 5941 trường hợp (True Positive), trong khi số False Negative (2007) tương đối thấp, cho thấy mô hình ít bỏ sót các quan sát thuộc lớp 1.
- Điều này cho thấy mô hình có độ nhạy (sensitivity/recall) tương đối tốt đối với lớp 1, nhưng phải đánh đổi bằng việc gia tăng số dự đoán sai dương tính.
- Tổng thể, mô hình phù hợp trong bối cảnh ưu tiên phát hiện lớp 1, tuy nhiên cần cải thiện khả năng phân biệt hai lớp nhằm giảm số lượng dự đoán sai lớp 1 khi thực tế thuộc lớp 0.

Bảng 35: Classification Performance Metrics của biến Diabetes_binary

Metric	**Value**
Accuracy	0.7304
95% Confidence Interval	(0.7265, 0.7342)
No Information Rate (NIR)	0.8433
P-value (Accuracy > NIR)	1
Kappa	0.3175
McNemar's Test P-value	$< 2 \times 10^{-16}$
Sensitivity (Recall)	0.7475
Specificity	0.7272
Positive Predictive Value (Precision)	0.3373
Negative Predictive Value	0.9394
Prevalence	0.1567
Detection Rate	0.1171
Detection Prevalence	0.3472
Balanced Accuracy	0.7373
Positive Class	1

Nhận xét:

- Nhìn chung, với Sensitivity = 0.7475, mô hình có khả năng phát hiện khá tốt các quan sát thuộc nhãn 1. Tuy nhiên, Positive Predictive Value = 0.3373 cho thấy trong các trường hợp mô hình dự đoán là nhãn 1, chỉ khoảng 34% là dự đoán đúng.

- Bên cạnh đó, Detection Prevalence = 0.3472 cho thấy mô hình dự đoán nhãn 1 cho khoảng 35% dữ liệu, trong khi Prevalence thực tế chỉ khoảng 15.7%. Điều này cho thấy mô hình không thiên về nhãn 0 mà có xu hướng dự đoán nhãn 1 nhiều hơn so với phân bố thực tế.

- Cách tiếp cận này phù hợp với bối cảnh mô hình chẩn đoán bệnh, nơi việc hạn chế bỏ sót các trường hợp dương tính được ưu tiên hơn so với việc giảm số lượng dự đoán dương tính giả.

Sau đấy, nhóm tiến hành xem xét đóng góp phi tuyến của ba biến định lượng trong bài toán này là *BMI,GenHlth, PhysHlth.*

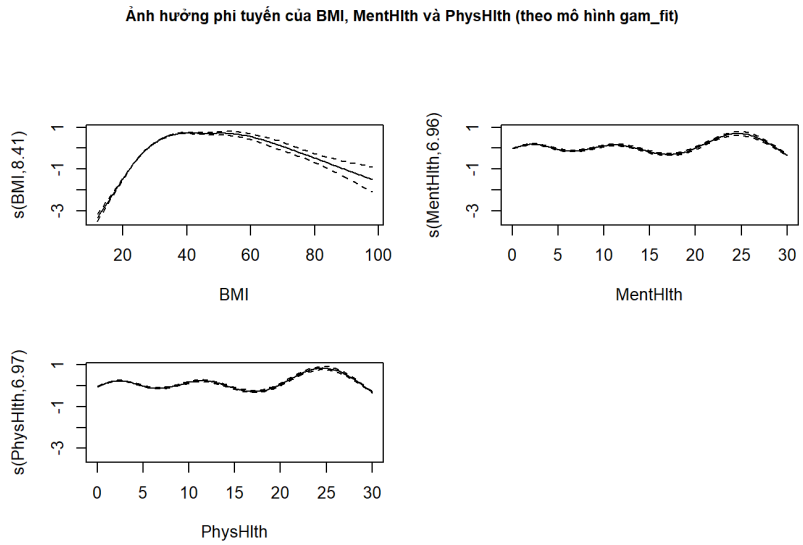

Hình 14: Ảnh hưởng phi tuyến của BMI, MentHlth và PhysHlth (theo mô hình gam_fit).

Nhận xét:

- BMI: Thấy rằng ảnh hưởng của BMI tăng mạnh ở vùng thấp -> trung bình, sau đó tăng chậm và đạt đỉnh khoảng BMI 35-45. Sau ngưỡng này, đường cong có xu hướng giảm nhẹ khi BMI rất cao, cho thấy quan hệ không tuyến tính hoàn toàn.
- MentHlth: Đường cong khá phẳng, dao động nhẹ quanh mức 0 → chứng tỏ MentHlth ảnh hưởng yếu lên xác suất lớp 1 trong mô hình này. Có xu hướng tăng nhẹ ở mức MentHlth cao (khoảng 20–25 ngày), nhưng nhìn chung tác động không mạnh.
- PhysHlth: PhysHlth có xu hướng tăng dần khi số ngày sức khỏe thể chất kém tăng, đặc biệt ở vùng khoảng 20–25 ngày.
- Nhìn chung trong 3 biến, BMI có ảnh hưởng rõ và mạnh nhất, còn MentHlth và PhysHlth ảnh hưởng nhẹ hơn và chủ yếu thể hiện biến thiên nhỏ theo hướng phi tuyến.

- Mối quan hệ phi tuyến không khác tác động nhiều đến mô hình, có lẽ đây là lý do mà so với mô hình Logistic, sự cải thiện lên GAM này không đáng kể.

7.4 Mô hình GAM giữa 21 biến đóng góp so với biến Diabetes_012.

Nhóm tiếp tục tiến hành mở rộng mô hình Logistic bằng cách mô hình hóa ảnh hưởng của biến liên tục dưới dạng hàm trơn, giúp bắt quan hệ phi tuyến. Nhóm sử dụng biến *Diabetes_012* đã được SMOTE nhằm tăng cường dữ liệu.

Để thực hiện được việc này nhóm sử dụng mô hình GAM được mở rộng cho bài toán phân loại đa lớp gồm ba nhãn (0/1/2) thông qua kỹ thuật one-vs-rest, trong đó mỗi lớp lần lượt được xem là lớp dương và được phân biệt với phần còn lại của dữ liệu.

Bảng 36: Confusion Matrix cho 3 nhãn phân loại

		Reference		
		0	**1**	**2**
Prediction	**0**	28485	282	1420
	1	7813	241	1746
	2	6490	357	3902

Nhận xét:

- Mô hình phân loại tốt đối với lớp 0, thể hiện qua số lượng dự đoán đúng cao (28 485), trong khi số trường hợp thuộc lớp 0 bị nhầm sang các lớp khác tương đối lớn, cho thấy lớp 0 chiếm ưu thế trong dữ liệu.

- Đối với lớp 1, số lượng dự đoán đúng (241) khá thấp so với tổng số quan sát thuộc lớp này, trong khi phần lớn các quan sát lớp 1 bị nhầm sang lớp 0 (282) hoặc lớp 2 (357), cho thấy mô hình gặp khó khăn trong việc phân biệt lớp 1 so với hai lớp còn lại (vì số mẫu ít).

- Lớp 2 được mô hình nhận diện ở mức trung bình, với 3 902 dự đoán đúng, tuy nhiên vẫn tồn tại nhầm lẫn đáng kể sang lớp 0 (1 420) và lớp 1 (1 746), phản ánh sự chồng lấn đặc trưng giữa các lớp trong không gian đặc trưng.

- Tổng thể, mô hình có xu hướng thiên về dự đoán lớp 0, trong khi hiệu năng đối với các lớp thiểu số (đặc biệt là lớp 1) còn hạn chế, cho thấy cần cân nhắc các biện pháp như điều chỉnh ngưỡng quyết định, gán trọng số lớp hoặc cải thiện đặc trưng đầu vào để nâng cao khả năng phân biệt giữa ba lớp.

Bảng 37: Overall Classification Performance

Metric	**Value**
Accuracy	0.6431
95% Confidence Interval	(0.6389, 0.6473)
No Information Rate (NIR)	0.8433
P-value (Accuracy > NIR)	1
Kappa	0.2331
McNemar's Test P-value	$< 2 \times 10^{-16}$

Bảng 38: Performance Metrics by Class

Metric	**Class 0**	**Class 1**	**Class 2**
Sensitivity	0.6657	0.2739	0.5521
Specificity	0.7859	0.8083	0.8432
Positive Predictive Value	0.9436	0.0246	0.3630
Negative Predictive Value	0.3040	0.9844	0.9208
Prevalence	0.8433	0.0173	0.1393
Detection Rate	0.5614	0.0048	0.0769
Detection Prevalence	0.5950	0.1932	0.2119
Balanced Accuracy	0.7258	0.5411	0.6976

Nhận xét:

- Khác với mô hình trước, mô hình này có Detection Prevalence ba lớp lần lượt là 0.5950, 0.1932, 0.2119. Tức khoảng 59.5% dự đoán là lớp 0, chỉ khoảng 40.5% là lớp 1 + 2 cộng lại. Mô hình chủ yếu dự đoán lớp 0, không phải lớp 1 và 2.

- Prevalence ba lớp lần lượt là 0.8433, 0.0173 và 0.1393. Mô hình giảm mạnh dự đoán lớp 0 (59.5% < 84.3%). Nhưng chưa đến mức "ưu tiên

lớp 1 2 hơn lớp 0". Nó chỉ bớt thiên lệch lớp 0, chứ chưa đảo chiều như mô hình trước.

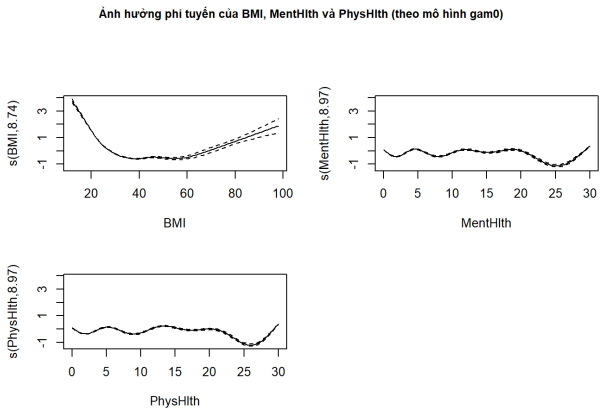

Hình 15: Ảnh hưởng phi tuyến của BMI, MentHlth và PhysHlth (theo mô hình gam0).

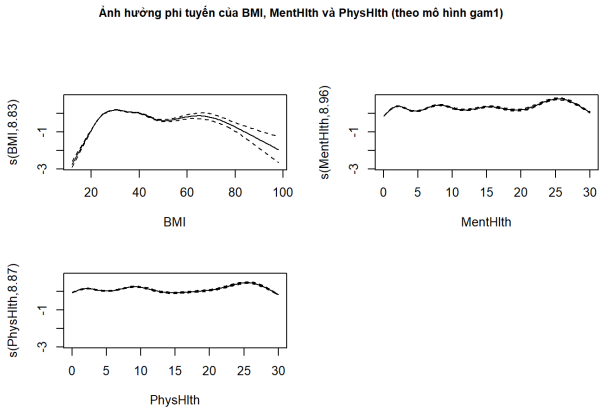

Hình 16: Ảnh hưởng phi tuyến của BMI, MentHlth và PhysHlth (theo mô hình gam1).

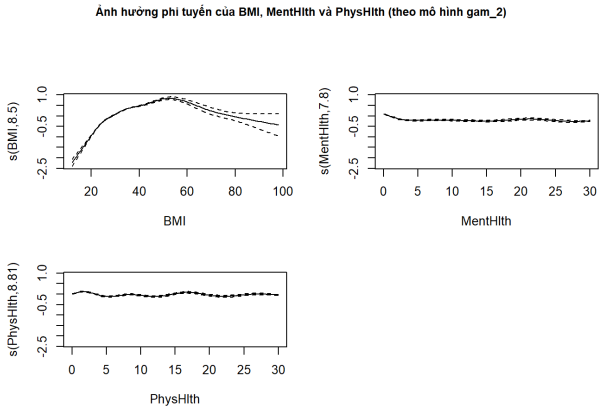

Hình 17: Ảnh hưởng phi tuyến của BMI, MentHlth và PhysHlth (theo mô hình gam2).

Nhận xét:

- Tương tự như mô hình trước, BMI là biến có tác động phi tuyến mạnh và ổn định nhất, ảnh hưởng thay đổi theo từng lớp (0/1/2).
- MentHlth là biến tín hiệu yếu, không phải yếu tố phân biệt mạnh giữa các lớp.
- PhysHlth nhìn chung ít tác động hơn BMI, chủ yếu dao động nhỏ và không tạo ranh giới mạnh giữa các lớp.

7.5 Mô hình GAM giữa 11 biến so với biến Diabetes_binary

Bảng 39: Confusion matrix cho mô hình GAM giữa 11 biến đóng góp so với biến Diabetes_binary.

		Reference	
		0	**1**
Prediction	**0**	30804	1967
	1	11984	5981

article **Nhận xét:**

- Mô hình dự đoán đúng không tiểu đường (TN) là 30,804 trường hợp, và dự đoán đúng tiểu đường (TP) là 5,981 trường hợp. Tuy nhiên vẫn có 11,984 trường hợp không tiểu đường bị dự đoán nhầm thành tiểu đường (False Positive), và 1,967 trường hợp tiểu đường bị bỏ sót (False Negative).

- Việc giảm bớt biến cho giúp mô hình cải thiện nhưng không đáng kể.

8 Đề xuất loại bỏ biến theo phương pháp đệ quy

8.1 Mục đích

Nhằm giảm số lượng biến đầu vào, tăng khả năng diễn giải và tránh hiện tượng dư thừa thông tin trong mô hình dự đoán tiểu đường, nhóm tiến hành lựa chọn biến theo phương pháp **loại bỏ đệ quy (Recursive Feature Elimination – RFE)** kết hợp với **Random Forest**.
Phương pháp này cho phép đánh giá tầm quan trọng của các biến thông qua hiệu năng dự đoán, từ đó xác định tập biến tối ưu mà vẫn duy trì độ chính xác cao.

8.2 Phương pháp thực hiện

Quy trình thực hiện lựa chọn biến bằng **phương pháp Recursive Feature Elimination (RFE)** được tiến hành theo các bước sau:

1. **Chuẩn bị dữ liệu:** Từ bộ dữ liệu ban đầu, tiến hành lấy ngẫu nhiên 5.000 quan sát nhằm giảm chi phí tính toán nhưng vẫn đảm bảo tính đại diện của mẫu.

2. **Xác định biến mục tiêu:** Biến mục tiêu được sử dụng là `Diabetes_binary`, trong đó giá trị 0 biểu thị nhóm không mắc tiểu đường và giá trị 1 biểu thị nhóm mắc tiểu đường.

3. **Lựa chọn tập biến giải thích:** Tổng cộng 21 biến giải thích liên quan đến tình trạng sức khỏe, hành vi và nhân khẩu học được đưa vào quá trình lựa chọn biến.

4. **Chia tập dữ liệu:** Dữ liệu được chia thành hai phần theo tỷ lệ 80% cho tập huấn luyện và 20% cho tập kiểm tra nhằm đánh giá hiệu năng mô hình.

5. **Mô hình RFE được huấn luyện với:**

   - Thuật toán nền: Random Forest.
   - Đánh giá hiệu năng mô hình: Phương pháp 10-fold cross-validation.
   - Chỉ số đánh giá chính: Accuracy.

8.3 Kết quả lựa chọn biến

Kết quả sau khi chạy mô hình:

```
##
## Recursive feature selection
##
## Outer resampling method: Cross-Validated (10 fold)
##
## Resampling performance over subset size:
##
##  Variables Accuracy   Kappa AccuracySD KappaSD Selected
##          1   0.8453 0.00000  0.0007864 0.00000
##          2   0.8408 0.01893  0.0070564 0.03155
##          3   0.8445 0.01533  0.0010812 0.02656
##          4   0.8435 0.16390  0.0084153 0.04976
##          5   0.8498 0.16948  0.0095626 0.04954        *
##          6   0.8485 0.13902  0.0102628 0.05391
##          7   0.8493 0.15676  0.0113429 0.06284
##          8   0.8485 0.13979  0.0111077 0.06354
##          9   0.8448 0.19385  0.0055872 0.03577
##         10   0.8413 0.17576  0.0063663 0.04156
##         11   0.8443 0.18862  0.0107877 0.05967
##         12   0.8465 0.18602  0.0096436 0.05828
##         13   0.8458 0.18149  0.0111613 0.06028
##         14   0.8460 0.17277  0.0097888 0.05760
##         15   0.8458 0.15668  0.0087951 0.05584
##         16   0.8455 0.19222  0.0106211 0.03992
##         17   0.8443 0.17166  0.0086809 0.04926
##         18   0.8440 0.16864  0.0071950 0.02797
##         19   0.8465 0.17036  0.0067659 0.04766
##         20   0.8480 0.17221  0.0068496 0.04912
##         21   0.8488 0.17602  0.0064909 0.04261
##
## The top 5 variables (out of 5):
##    GenHlth, BMI, HighBP, Age, DiffWalk
```

Hình 18: Kết quả Accuracy của 21 biến khi chạy RFE

Biểu đồ trực quan:

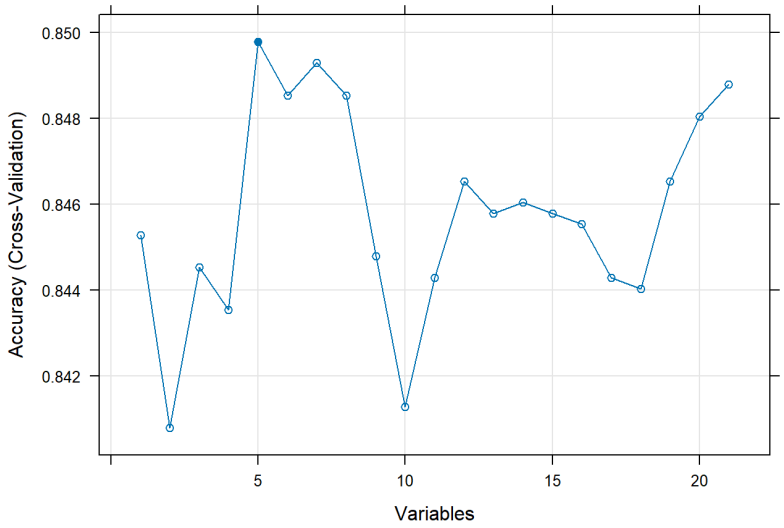

Hình 19: Trực quan Accuracy của 21 biến khi chạy RFE

5 biến quan trọng nhất được lựa chọn bao gồm:

- GenHlth: Tình trạng sức khỏe tổng quát
- BMI : Chỉ số khối cơ thể
- HighBP : Cao huyết áp
- Age: Độ tuổi
- DiffWalk: Tình trạng đi lại khó khăn

Nhận xét: Kết quả RFE cho thấy mô hình đạt độ chính xác cao nhất khi sử dụng 5 biến, với Accuracy trung bình khoảng 84.98%, tương đương so với các mô hình sử dụng nhiều biến hơn.

Kết luận: Vậy kết quả cho thấy việc đưa toàn bộ 21 biến vào mô hình không cải thiện đáng kể độ chính xác dự đoán (Accuracy). Điều này cho thấy một tập biến rút gọn vẫn có thể duy trì hiệu năng tương đương, đồng thời giúp mô hình đơn giản và hiệu quả hơn.

Tài liệu